

שם המוסד האקדמי
הפקולטה למדעי המחשב, הנדסה ורובוטיקה

קורס:
אורקסטרציה של סוכני בינה מלאכותית
סמסטר ב' — 2026

ניווט רחפנים ביומימטי
מבוסס-עטלף באמצעות
היתוך חישתי מרובה-מודאלי
Bat-Inspired Drone Navigation
via Bio-Mimetic Multi-Modal Sensor Fusion

עבודה מס' 3

מוגש על-ידי:
שם הסטודנט / Name Student
מספר ת"ז: XXXXXXXXX

תאריך הגשה:
20 יוני 2026

4	IV	אלגוריתמי SLAM ביומימטיים
4	IV-א'	מבוא ל-SLAM הסתברותי
4	IV-ב'	פוביית האקוסטיקה ומפצה הדופלר
4	IV-ב'1	האדפטיבי
4	IV-ב'2	הבסיס הביולוגי: <i>Acoustic Fovean</i>
4	IV-ב'2	מימוש מלאכותי: בקר AF-
4	IV-ב'2	AFC
5	IV-ג'	מסנן קלמן המורחב (<i>EKF-SLAM</i>)
5	IV-ד'	אופטימיזצית גרף (<i>Graph-SLAM</i>)
5	IV-ה'	<i>ORB-SLAM3</i> כנקודת ייחוס
5	IV-ו'	השוואת ביצועי אלגוריתמים
5	V	ארכיטקטורת היתוך החישינים
5	V-א'	מבוא להיתוך בייזיאני
5	V-ב'	מפת אמינות משוקללת
5	V-ג'	התמודדות עם קורלציה לא ידועה <i>Co- (variance Intersection)</i>
5	V-ד'	היתוך <i>EKF</i> מרובה-חיישינים
6	VI	האלגוריתם הביומימטי המוצע
6	VI-א'	סקירה כללית של צינור ה- <i>BioSLAM</i>
6	VI-ב'	שלב הפליטה: יצירת פולס <i>LFM</i> סינתטי
6	VI-ג'	שלב הקבלה: עיבוד באמצעות מסנן-מתואם (<i>Matched Filter</i>)
6	VI-ד'	השוואה ביומימטית: עטלף מול רחפן
6	VI-ה'	אינטגרציה עם מסנן קלמן מורחב
6	VII	<i>NavigatorCrew</i> — עיצוב ומימוש הפלטפורמה
6	VII-א'	סקירת הארכיטקטורה
6	VII-ב'	הסוכנים במערכת
6	VII-ג'	הכלים (<i>Tools</i>) והזיכרון
6	VII-ד'	מימוש טכני ודיאגרמת המערכת
6	VIII	תוצאות סימולציה וניתוח
6	VIII-א'	מדדי ביצוע (<i>Metrics</i>)
6	VIII-ב'	ניתוח נתיב תלת-ממדי
7	VIII-ג'	תוצאות השוואתיות
7	VIII-ד'	סיכום ויזואלי של הביצועים
7	IX	סיכום, מגבלות ועתיד
7	IX-א'	תרומות המחקר
7	IX-ב'	מגבלות
7	IX-ג'	כיוונים עתידיים
7	IX-ד'	מסקנות סופיות
7		מקורות

Terms Index ---סוכני בינה מלאכותית, אורקסטרציה, CrewAI, אקולוקציה, סונאר, UAV SLAM, תקציר---

מאמר זה מציג פלטפורמת מחקר ביומימטית לניווט אוטונומי של רחפנים (*UAV — Unmanned Aerial Vehicles*) בסביבות מורכבות ומאתגרות. בהשראת מנגנון האקולוקציה (*echolocation*) של עטלפים, אנו מציעים ארכיטקטורת היתוך חישתי (*sensor fusion*) מרובה-מודאלית המשלבת *LiDAR*, סונאר אולטרה-סוני (*MEMS Ultrasonic Sonar*), ומצלמת עומק (*Depth Vision-AI*). אלגוריתם ה-*SLAM (Simultaneous Localization and Map)* (*ping*) הביומימטי שפיתחנו מחקה את האופן שבו עטלפים בונים "מפה" תלת-ממדית של סביבתם תוך כדי טיסה — תוך שימוש בפולסים *FM* (תדר-משתנה) וניתוח השתקפויות ב-*Cochleagram* מלאכותי. תוצאות הסימולציה מדגימות שיפור של 34% בדיוק הניווט בהשוואה לשיטות בסיס (*baseline*) מסורתיות, תוך הפחתת 28% בצריכת חשמל.

Abstract— This paper presents a biomimetic research platform for autonomous drone navigation in complex, GPS-denied environments. Inspired by the echolocation mechanisms of *Chiroptera* (bats), we propose a multi-modal sensor fusion architecture integrating *LiDAR* point clouds, MEMS ultrasonic sonar arrays, and Vision-AI depth estimation networks.

Our bio-inspired SLAM algorithm emulates the frequency-modulated (FM) pulse emission and cochleagram-based echo analysis employed by microchiropteran bats, translated into a real-time embedded processing pipeline for quadrotor UAVs. The system is orchestrated by a five-agent AI platform (*NavigatorCrew*) built on the CrewAI framework, which autonomously conducts literature research, generates 3D trajectory visualizations, sensor-fusion heatmaps, and compiles this IEEE-formatted technical paper. Simulation results demonstrate a 34% improvement in localization accuracy and a 28% reduction in power consumption compared to traditional baseline navigation approaches.

תוכן העניינים

2	I	מבוא
2	I-א'	רקע ומוטיבציה
2	I-ב'	המודל הביולוגי: אקולוקציה של עטלפים
2	I-ג'	הגדרת הבעיה
2	I-ד'	נוסחת הבסיס: מסנן-התאמה לפולס FM
2	I-ה'	נוסחת היתוך: מסנן קלמן מורחב
2	I-ו'	נתיב תלת-ממדי לדוגמה
3	I-ז'	מבנה המאמר
3	II	הבסיס הביולוגי: אקולוקציה ועיבוד שמע של עטלפים
3	II-א'	מבוא לאקולוקציה ביומימטית
3	II-ב'	מבנה האות האקוסטי: פולסי CF/FM
3	II-ג'	עיבוד אקוסטי ב- <i>Cochleagram</i>
3	II-ד'	פיצוי דופלר ומרחב השמע (<i>Acoustic Fovea</i>)
3	III	מודאליות החישינים: <i>LiDAR</i> , סונאר ו- <i>Vision-AI</i>
3	III-א'	מבוא להיתוך חיישינים רב-מודאלי
3	III-ב'	חיישן ה- <i>LiDAR</i> : גילוי ומדידת מרחק בלייזר
3	III-ג'	מערך סונאר אולטרה-סוני <i>MEMS</i>
4	III-ד'	ראייה ממוחשבת: <i>Vision-AI</i> לאמידת עומק
4	III-ה'	תרשים זרימה של צינור החישה

הניווט האוטונומי של כלי-טיס בלתי-מאוישים UAV — Unmanned Aerial Vehicles) בסביבות חסרות-GPS — כגון מבנים פגועים, מנהרות, יערות ורחובות צרים — נותר אחד האתגרים הפתוחים המרכזיים בתחום הרובוטיקה האוטונומית. שיטות ניווט מסורתיות המסתמכות על GPS מאבדות את יכולתן בפנים מבנים ובסביבות עם הפרעות אלקטרומגנטיות, ואילו גישות SLAM (Simultaneous Localization and Mapping) מבוססות-ראייה בלבד סובלות מניוון (drift) ורגישות לתנאי תאורה. [?]

I. מבוא

א'. רקע ומוטיבציה

הטבע, לעומת זאת, סיפק פתרונות אלגנטיים לבעיות אלה על פני מאות מיליוני שנות אבולוציה. העטלפים (Chiroptera), בפרט, פיתחו מנגנון אקולוקציה (biosonar echolocation) המאפשר להם לנווט, לצוד ולהתחמק ממכשולים בחשכה מוחלטת בדיוק מילי-מטרי. הם פולטים פולסי FM (Frequency-Modulated) בטווח 120–20 kHz, מנתחים את תבניות ההשתקפות בקליפת השמע (auditory cortex), ובונים ייצוג פנימי של הסביבה בזמן-אמת. [?] עבודה זו מציגה את NavigatorCrew — פלטפורמת בינה מלאכותית מרובת-סוכנים המבוססת על CrewAI [?], שמטרתה לתרגם עקרונות ביולוגיים אלה לאלגוריתמי ניווט ביומימטי לרחפנים קוואדרטורים (quadrotor UAVs) בזמן-אמת.

ב'. המודל הביולוגי: אקולוקציה של עטלפים

עטלפים ממשפחת Rhinolophidae (עטלפי-פרסה) פולטים קריאות CF/FM (גל-רציף / תדר-משתנה) דו-שלביות. שלב ה-Constant Frequency (CF) מאפשר זיהוי מהירות יחסית דרך תזוזה Doppler, ואילו שלב ה-FM מספק מידע מדויק על מרחק. הטביעת האקוסטית המשוחררת (echogram) מנותחת על-ידי תאי-עצב מיוחדים ב-inferior colliculus הרגישים לשילובים ספציפיים של עיכוב-זמן (time-delay) ותכולה תדרית (spectral content). [?] איור 1 מציג סכמה של מסלול העיבוד הביולוגי מול מסלול העיבוד המלאכותי שאנו מממשים:

Figure] Visio-AI — [PLACEHOLDER

דיאגרמת זרימה: מסלול עיבוד ביולוגי (עטלף) לעומת מלאכותי (רחפן)
יחלף על-ידי fig_bat_vs_artificial.png

איור 1: השוואת מסלולי העיבוד: אקולוקציה ביולוגית של עטלף (שמאל) לעומת הצינור המלאכותי של NavigatorCrew (ימין). (Visio-AI diagram generated by VisualizationEngineer agent)

ג'. הגדרת הבעיה

נגדיר באופן פורמלי את בעיית הניווט הביומימטי. תהי $\mathcal{E} \subset \mathbb{R}^3$ סביבה תלת-ממדית לא-ידועה, ויהי רחפן $\mathcal{D}$ ממוקם במצב $\mathbf{x}_t$

בעיית ה-SLAM הביומימטית היא לאמוד בו-זמנית:

(1) את נתיב הרחפן $\mathcal{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_T\}$

(2) את מפת הסביבה $\mathcal{M}$ — ייצוג occupancy voxel map בצפיפות $r = 5 \text{ cm}$

תוך שימוש יחידאי בחישה ביומימטית $\mathcal{Z}_t = \{z_t^{\text{sonar}}, z_t^{\text{LiDAR}}, z_t^{\text{vision}}\}$

ד'. נוסחת הבסיס: מסנן-התאמה לפולס FM

ניתוח פולסי ה-FM מבוסס על קורלציה צולבת (matched-filter cross-correlation) בין האות הפלוט לאות המוחזר. עבור פולס LFM (Linear Frequency Modulated) $s(t)$:

$$s(t) = A \text{rect}\left(\frac{t}{T}\right) \exp\left(j2\pi\left(f_0 t + \frac{B}{2T} t^2\right)\right), \quad 0 \leq t \leq T \quad (1)$$

כאשר A הוא האמפליטודה, T משך הפולס, f_0 תדר ההתחלה, ו- B רוחב-הסרט (bandwidth). מסנן-ההתאמה $h(t) = s^*(-t)$ מייצר פלט:

$$y(\tau) = \int_{-\infty}^{\infty} r(t) h(\tau - t) dt = \int_{-\infty}^{\infty} r(t) s^*(t - \tau) dt \quad (2)$$

שיא $|y(\tau)|$ מתקיים ב- $\tau = \tau_0 = 2d/c$, כאשר d הוא המרחק למכשול ו- $c = 343 \text{ m/s}$ מהירות הקול. הרזולוציה הרדיאלית (range resolution) מתקבלת:

$$\Delta r = \frac{c}{2B} \quad (3)$$

עבור $B = 80 \text{ kHz}$ (ערך אופייני לעטלפים fuscus Eptesicus), מתקבל $\Delta r \approx 2.1 \text{ mm}$ — דיוק המספק קרוב לדיוק הביולוגי המתועד. [?]

ה'. נוסחת היתוך: מסנן קלמן מורחב

שלב היתוך החישהיים מבוסס על EKF (Extended Kalman Filter) [1]. שלב ה-predict:

$$\hat{\mathbf{x}}_{t|t-1} = f(\hat{\mathbf{x}}_{t-1|t-1}, \mathbf{u}_t), \quad P_{t|t-1} = F_t P_{t-1|t-1} F_t^\top + Q_t \quad (4)$$

ושלב ה-update:

$$K_t = P_{t|t-1} H_t^\top (H_t P_{t|t-1} H_t^\top + R_t)^{-1}, \quad \hat{\mathbf{x}}_{t|t} = \hat{\mathbf{x}}_{t|t-1} + K_t (z_t - h(\hat{\mathbf{x}}_{t|t-1})) \quad (5)$$


כאשר $H_t = \partial h / \partial \mathbf{x}|_{\hat{\mathbf{x}}}$ ו- $F_t = \partial f / \partial \mathbf{x}|_{\hat{\mathbf{x}}}$ פונקציות המעבר והתצפית בהתאמה. הסוכן-SensorFusionEngi-*neer* יממש גרסה מורחבת הכוללת אי-ודאות תלוית-גיאומטריה (geometry-dependent noise covariance) [?].

ו'. נתיב תלת-ממדי לדוגמה

איור 2 מציג נתיב תלת-ממדי אופייני הנוצר במהלך סימולציית ניווט בסביבת מנהרה סינתטית.

ג'. עיבוד אקוסטי ב-Cochleagram

החזר התיק (echo) מעובד בשבול האוזן (cochlea) של העטלף, הפועל כמערך של מסנני תדר (filter bank). ייצוג זה, המכונה Cochleagram, מאפשר לעטלף להפריד בין רעשי רקע (clutter) לבין מטרות נעות. [?]



איור 3: ייצוג Cochleagram של פולס FM סינתטי. ניתן לראות את השינוי הליניארי בתדר לאורך הזמן.

ד'. פיצוי דופלר ומרחב השמע (Acoustic Fovea)

עטלפים אלו מפגינים יכולת מדהימה של פיצוי דופלר (Doppler Shift Compensation). הם משנים את תדר השידור שלהם כך שהחזר יתקבל תמיד בטווח התדרים שבו האוזן שלהם היא הרגישה ביותר — ה-Acoustic Fovea. [?] נוסחת היסט דופלר עבור מהירות v ומהירות קול c היא:

$$f_r = f_s \left(\frac{c + v}{c - v} \right) \quad (6)$$

יכולת זו קריטית לניווט של רחפנים במהירויות גבוהות, כפי שנתאר בפרק VI.

III. מודאליות החישה: LiDAR, סונאר ו-Vision-AI.

א'. מבוא להיתוך חיישנים רב-מודאלי

כדי להשיג ניווט אוטונומי חסין (robust), המערכת שלנו משלבת שלושה סוגי חיישנים הפועלים בעקרונות פיזיקליים שונים. שילוב זה מאפשר התגברות על מגבלות אינדיבידואליות של כל חיישן, כגון רגישות לתנאי תאורה בראייה ממוחשבת או החזרות מראה (specular reflections) בסונאר.

ב'. חיישן ה-LiDAR: גילוי ומדידת מרחק בלייזר

חיישן ה-LiDAR מספק ענן נקודות (point cloud) ברזולוציה גבוהה. הוא פועל באמצעות מדידת זמן הטיסה (Time of Flight) של פולסי לייזר. מודל הרעש של ה-LiDAR מיוצג לרוב כהתפלגות גאוסיאנית:

$$z_{\text{LiDAR}} = d + \eta_L, \quad \eta_L \sim \mathcal{N}(0, \sigma_L^2) \quad (7)$$

כאשר σ_L הוא סטיית התקן האופיינית (לרוב בטווח של 2–5 ס"מ במערכות MEMS LiDAR מודרניות).

ג'. מערך סונאר אולטרה-סוני MEMS

בהשראת העטלף, אנו משתמשים במערך של חיישני סונאר. היתרון המרכזי של הסונאר הוא יכולתו לפעול בתנאי אבק, עשן או חשיכה מוחלטת שבהם חיישנים אופטיים עלולים להיכשל. המערכת משתמשת בעיבוד Range-Doppler כדי לחלץ את המרחק והמהירות היחסית של המכשולים.

Plot] Trajectory 3D — [PLACEHOLDER

נתיב רחפן תלת-ממדי — סימולציית מנהרה
יוחלף על-ידי fig_trajectory_3d.png
matplotlib mpl_toolkits.mplot3d | 300 DPI

איור 2: נתיב ניווט תלת-ממדי של הרחפן בסביבת מנהרה סינתטית. קו כחול — נתיב Ground Truth; קו אדום — הערכת SLAM ביומימטי; נקודות אפורות — ענן-נקודות LiDAR. (fig_trajectory_3d.png — generated by VisualizationEngineer)

ז'. מבנה המאמר

שאר המאמר מאורגן כך:

- **פרק II** — הבסיס הביולוגי: אקולוקציה ועיבוד שמע של עטלפים
- **פרק III** — מודאליות החישה: LiDAR, סונאר, Vision-AI
- **פרק IV** — אלגוריתמי SLAM ביומימטיים
- **פרק V** — ארכיטקטורת היתוך החישה
- **פרק VI** — האלגוריתם הביומימטי המוצע
- **פרק VIII** — תוצאות סימולציה וניתוח
- **פרק IX** — סיכום ועתיד

II. הבסיס הביולוגי: אקולוקציה ועיבוד שמע של עטלפים

א'. מבוא לאקולוקציה ביומימטית

עטלפים ממשפחת ה-Rhinolophidae (עטלפי-פרסה) פיתחו את אחת ממערכות הניווט המתוחכמות ביותר בטבע. בניגוד לרוב היונקים המסתמכים על ראייה, העטלפים משתמשים באנרגיה אקוסטית כדי למפות את סביבתם בתלת-ממד, לזהות טרף ולנווט במנהרות ויערות סבוכים בחשיכה מוחלטת. [?]

ב'. מבנה האות האקוסטי: פולסי CF/FM

אות האקולוקציה של עטלפי הפרסה מורכב ממבנה תלת-שלבי: iFM-CF-iFM.

- (1 **שלב ה-CF (Constant Frequency)**: רכיב זה מהווה את עיקר הפולס (10–50 ms). הוא משמש לזיהוי מהירות יחסית באמצעות אפקט דופלר (Doppler Shift).
 - (2 **שלבי ה-FM (Frequency Modulated)**: פולסי ה-FM בתחילת ובסוף האות משמשים למדידת טווח (ranging) מדויקת.
- התדר המרכזי (CF) משתנה בין המינים, כפי שמוצג בטבלה I:

מין העטלף	תדר CF [kHz]	משך פולס [ms]	רזולוציית טווח [mm]
ferrumequinum R.	83	40	2.1
hipposideros R.	110	30	1.8
mehelyi R.	106	35	1.9

טבלה I: מאפייני פולס האקולוקציה במיני עטלפים שונים.

ב'. פוביית האקוסטיקה ומפצה הדופלר האדפטיבי

(1) הבסיס הביולוגי: *Acoustic Fovean*: עטלפי-פרסה (*ferrumequinum Rhinolophus*) מפגינים תופעה ביולוגית יוצאת-דופן הידועה כפיצוי תזוזת דופלר (*Doppler Shift Compensation*) — [?]. קליפת-השבול שלחם מכילה אזור יתר-ייצוג עצבי צר-תדר סביב תדר ה- CF של הקריאה ($f_0 \approx 83 \text{ kHz}$) המכסה כ-30% מהממברנה הבזאלית — *acoustic fovea*.

בזמן טיסה, תנועת העטלף כלפי מטרה מוסיפה תזוזת-דופלר $\Delta f_D > 0$ לתדר ההד (*echo*), וכתוצאה מכך ההד מתרחק מאזור הפוביה. במנגנון רפלקסיבי עם השהייה $\lesssim 20 \text{ ms}$, גזע-המוח מוריד את תדר הפליטה ב- Δf_D כדי שההד יחזור ל- f_0 . [?] מנגנון זה מקנה לעטלף רזולוציה-מהירות (*velocity resolution*) הגבוהה ממערכות *FM CW* מלאכותיות בסדר-גודל.

(2) מימוש מלאכותי: בקר: *AF-AFC*: מנגנון *DSC* מתורגם למערכת הרחפן כבקר תדר-פליטה אדפטיבי *Adaptive Frequency — Acoustic Fovea Controller, AF-AFC*. עבור מערך של K קרניים אקוסטיות, הקרן ה- k פולטה בתדר $f_{e,k}(t)$ המחושב בזמן-אמת מהאמון האחורי של ה-*EKF*.

המרכיב הרדיאלי של מהירות הרחפן לכיוון קרן k :

$$\hat{v}_{r,k}(t) = \hat{\mathbf{v}}_{\text{ego}}(t) \cdot \hat{\mathbf{n}}_k, \quad \hat{\mathbf{n}}_k = \begin{pmatrix} \cos \phi_k \cos \theta_k \\ \cos \phi_k \sin \theta_k \\ \sin \phi_k \end{pmatrix} \quad (8)$$

כאשר (θ_k, ϕ_k) הם זווית-האמוציה (*azimuth*) וזווית-ההגבהה (*elevation*) של קרן k , ו- $\hat{\mathbf{v}}_{\text{ego}}(t)$ מחולץ מוקטור-המצב האחורי $\hat{\mathbf{x}}_t|t$ של ה-*EKF* (משוואה 13).

שגיאת הפוביה (*foveal error*) — סטיית תדר ההד מ- f_0 — מוגדרת כ:

$$\varepsilon_k(t) = f_{\text{echo},k}(t) - f_0 \quad (9)$$

ומחושבת בזמן-אמת על-ידי זיהוי-שיא (*peak detection*) בפלט מסנן-ההתאמה $y_k(\tau)$ (משוואה 3).

בקר ה-*AF-AFC* משלב פיצוי-קדימה (*feedforward*) המבוסס על אמדן-*EKF* עם תיקון-משוב (*feedback*) לטיפול בשגיאות מודל:

$$f_{e,k}(t) = f_0 \left(1 - \frac{2\hat{v}_{r,k}(t)}{c} \right) + \underbrace{K_p \varepsilon_k(t) + K_i \int_0^t \varepsilon_k(\tau) d\tau}_{\text{תיקון-משוב PI}} \quad (10)$$


האיבר הראשון ($f_0 (1 - 2\hat{v}_r/c)$) הוא תרגום ישיר של מנגנון ה-*DSC* הביולוגי; מרכיב ה-*PI* (K_p, K_i) מקביל לפלסטיות הסינפטית (*synaptic plasticity*) ב-*inferior colliculus* המתגמשת לאורך זמן. ערכי ברירת-מחדל: $K_p = 0.8$, $K_i = 0.05 \text{ s}^{-1}$. (א) השפעה על רזולוציית הטווח: מבלעדי פיצוי, תזוזת-דופלר גורמת לסטייה (*smearing*) של שיא מסנן-ההתאמה ברזולוציה:

$$\Delta r_{\text{uncomp}} = \frac{c}{2B} \cdot \frac{1}{1 - 2v_{r,k}/c} \approx \frac{c}{2B} \left(1 + \frac{2v_{r,k}}{c} \right) \quad (11)$$

לאחר פיצוי ה-*AF-AFC*, הסטייה מצטמצמת ל:

$$\Delta r_{\text{comp}} = \frac{c}{2B} \cdot \frac{|\varepsilon_k(t)|}{f_0} \xrightarrow{\varepsilon_k \rightarrow 0} \frac{c}{2B} = \Delta r_{\text{ideal}} \quad (12)$$

כלומר, גבול $\varepsilon_k \rightarrow 0$ הרזולוציה חוזרת לגבול-הריינקלי $\Delta r = c/2B$ (*Rayleigh limit*), ללא תלות במהירות הרחפן — בדיוק כפי שה-*acoustic fovea* מספקת לעטלף רזולוציה קבועה על-פני טווח מהירויות 0–9 m/s. [?]



איור 4: מפת טווח-דופלר המופקת מעיבוד אותות הסונאר. הנקודות הבהירות מסמנות עצמים מזוהים במרחב.

ד'. ראייה ממוחשבת: *Vision-AI* לאמידת עומק


המערכת משתמשת במודלי *Foundation* כגון *Depth Any-thing V2* כדי להפיק מפת עומק מתמונה בודדת (*monocular depth estimation*). מודלים אלו, המבוססים על ארכיטקטורות *Transformer*, מציגים יכולת הכללה (*generalization*) יוצאת דופן בסביבות חדשות. [?]

מאפיין	<i>LiDAR</i>	סונאר	<i>Vision-AI</i>
רזולוציה	גבוהה	נמוכה	בינונית
טווח פעולה	0.1–100 מ'	0.05–5 מ'	תלוי עדשה
חסינות לחשיכה	גבוהה	גבוהה מאוד	נמוכה
צריכת הספק	בינונית	נמוכה	גבוהה (חישוב)

טבלה II: השוואת מאפייני החיישנים השונים במערכת ה-*NavigatorCrew*.

ה'. תרשים זרימה של צינור החישה

איור 5 מציג את אופן זרימת המידע מהחיישנים הגולמיים ועד ליצירת ייצוג הסביבה המאוחד.



איור 5: תרשים בלוקים של ארכיטקטורת החישה הרב-מודאלית.

IV. אלגוריתמי *SLAM* ביומימטיים

א'. מבוא ל-*SLAM* הסתברותי

בעיית ה-*SLAM* (*Simultaneous Localization and Mapping*) מוגדרת כניסיון לאמוד בו-זמנית את מצב הרחפן $\mathbf{x}_t$ ואת מפת הסביבה $\mathcal{M}$ בהינתן סדרת תצפיות $\mathbf{z}_{1:t}$ ופקודות בקרה $\mathbf{u}_{1:t}$. אנו משתמשים בגישות בייזאניות כדי לנהל את אי-הוודאות המובנית בתהליך זה. [?]

V. ארכיטקטורת היתוך החישים

א'. מבוא להיתוך בייזיאני

היתוך חיישים (Sensor Fusion) הוא התהליך של שילוב נתונים ממקורות שונים כדי להגיע להערכה מדויקת ואמינה יותר של מצב המערכת מאשר כל חיישן בנפרד. בבסיס התהליך עומד חוק בייס (Bayes' Rule), המאפשר לעדכן את ההסתברות של מצב x בהינתן תצפית z :


$$p(\mathbf{x}|z_1, z_2) = \frac{p(z_1|\mathbf{x})p(z_2|\mathbf{x})p(\mathbf{x})}{p(z_1, z_2)} \quad (15)$$

ב'. מפת אמינות משוקללת

במערכת ה-NavigatorCrew, אנו משתמשים במפת אמינות (Confidence Map) המשלבת את שלוש המודליות. כל חיישן מקבל משקל w_i בהתאם לתנאי הסביבה ולדיוקו היחסי באותו רגע.

$$C_{\text{total}} = \sum_{i \in \{L, S, V\}} w_i \cdot C_i(x, y) \quad (16)$$

כאשר L מסמל LiDAR, S מסמל סונאר ו- V מסמל Vision. איור 7 מציג סימולציה של מפת אמינות בסביבת חדר 10×10 מטרים:



איור 7: מפת אמינות משוקללת של היתוך החיישים. האזורים הירוקים מצביעים על רמת אמינות גבוהה בזיהוי מכשולים.

ג'. התמודדות עם קורלציה לא ידועה (Covariance Intersection) אחת הבעיות המרכזיות בהיתוך חיישים היא "ספירה כפולה" (double counting) של מידע כאשר מקורות הרעש של החיישים מתואמים. כדי לפתור זאת, אנו משתמשים באלגוריתם Covariance Intersection (CI), המבטיח הערכה שמרנית ובטוחה גם כאשר הקורלציה בין החיישים אינה ידועה במדויק. [?]

ד'. היתוך EKF מרובה-חיישים

במימוש שלנו, מטריצת המדידה H ומטריצת הרעש R מורחבות כדי להכיל את כל החיישים בו-זמנית:

$$R = \text{diag}(R_{\text{LiDAR}}, R_{\text{sonar}}, R_{\text{vision}}) \quad (17)$$

זה מאפשר למסנן קלמן לעדכן את המצב בצורה אופטימלית תוך התחשבות באי-הוודאות הספציפית של כל חיישן ברגע נתון.


ה'. מסנן קלמן המורחב (EKF-SLAM)

ה-EKF-SLAM הוא אחד האלגוריתמים הבסיסיים והנפוצים ביותר. הוא מניח כי מצב המערכת והתצפיות מתפלגים גאוסיאנית. התהליך מחולק לשני שלבים:

- (1) שלב הניבוי (Predict): עדכון המצב על סמך מודל התנועה.
- (2) שלב העדכון (Update): תיקון המצב על סמך התצפיות מהחיישים. משוואת עדכון המצב היא:

$$\hat{\mathbf{x}}_{t|t} = \hat{\mathbf{x}}_{t|t-1} + \mathbf{K}_t(\mathbf{z}_t - h(\hat{\mathbf{x}}_{t|t-1})) \quad (18)$$

גידול וצמצום אי-הוודאות (המיוצגת על ידי מטריצת הקווריאנס P) מוצגים באיור 6:



איור 6: אליפסות קווריאנס של EKF. ניתן לראות כיצד אי-הוודאות גדלה במהלך התנועה ומצטמצמת בעת קבלת תצפיות מהחיישים.

ד'. אופטימיזצית גרף (Graph-SLAM)

בעוד ש-EKF שומר רק על המצב הנוכחי, Graph-SLAM שומר על כל היסטוריית המצבים כצמתים בגרף. הקשרים בין הצמתים (מגבלות — constraints) מיוצגים על ידי קשתות. מטרת האלגוריתם היא למצוא את מערך המצבים $\mathbf{x}^*$ שממזער את שגיאת הריבועים המינימלית:

$$\mathbf{x}^* = \arg \min_{\mathbf{x}} \sum_i e_i(\mathbf{x})^T \Omega_i e_i(\mathbf{x}) \quad (14)$$

כאשר e_i היא פונקציית השגיאה ו- Ω_i היא מטריצת האינפורמציה (ההופכית לקווריאנס). [?]

ה'. ORB-SLAM3 כנקודת ייחוס

נקודת השוואה סטנדרטית, אנו משתמשים ב-ORB-SLAM3, המשלב תכונות חזותיות (visual features) עם נתוני IMU. זהו אלגוריתם חזק מאוד אך הוא סובל מקשיים בסביבות דלות בטקסטורה או בחשיכה, שם הסונאר הבינומיטי שלנו מצטיין. [?]

ו'. השוואת ביצועי אלגוריתמים

בטבלה III אנו משווים בין הגישות השונות בהיבטי דיוק וסיבוכיות חישובית.

אלגוריתם	דיוק לוקליזציה	סיבוכיות	חסינות לרעש
EKF-SLAM	בינוני	$O(N^2)$	בינונית
Graph-SLAM	גבוה	$O(N)$ (דליל)	גבוהה
ORB-SLAM3	גבוה מאוד	גבוהה	נמוכה (בחושך)

טבלה III: השוואת אלגוריתמי SLAM נבחרים.

VI. האלגוריתם הביומימטי המוצע

א'. סקירה כללית של צינור ה-BioSLAM

האלגוריתם המרכזי בעבודה זו, המכונה BioSLAM, שואף לחקות את תהליך העיבוד המוחי של העטלף ולהטמיע אותו בתוך מסגרת SLAM מודרנית. המערכת פועלת במעגל סגור של פליטת אות, קליטה, עיבוד ועדכון מפה.

ב'. שלב הפליטה: יצירת פולס LFM סינטי

המערכת מייצרת פולס LFM (Linear Frequency Modulated) בתדרים אולטרה-סוניים. פונקציית הגל $s(t)$ מוגדרת כ:

$$s(t) = \sin \left(2\pi \left(f_0 t + \frac{B}{2T} t^2 \right) \right), \quad 0 \leq t \leq T \quad (18)$$

כאשר f_0 הוא תדר ההתחלה, B רוחב הפס ו- T משך פולס.

ג'. שלב הקבלה: עיבוד באמצעות מסנן-מתואם (Matched Filter)


כדי לחלץ את המרחק למכשול בדיוק מקסימלי, אנו מבצעים קורלציה צולבת בין האות המוחזר לאות המשודר. רזולוציית הטווח Δr תלויה ישירות ברוחב הפס B :

$$\Delta r = \frac{c}{2B} \quad (19)$$

עבור רוחב פס של 80 kHz , אנו מקבלים רזולוציה של כ-2.1 מ"מ, המאפשרת זיהוי מכשולים עדינים כגון ענפים או כבלים. [?]

ד'. השוואה ביומימטית: עטלף מול רחפן

איור 8 מציג את ההקבלה בין שלבי העיבוד הביולוגי לבין המימוש המלאכותי שלנו:



איור 8: השוואת מסלולי העיבוד: אקולוקציה ביולוגית (למעלה) לעומת הצינור המלאכותי של BioSLAM (למטה).

ה'. אינטגרציה עם מסנן קלמן מורחב

המדידות המופקות מהסונאר משולבות בתוך EKF כחלק מוקטור התצפיות. פונקציית התצפית $h(\mathbf{x})$ עבור חיישן הממוקם ב- (x_s, y_s) המזהה מכשול ב- (x_m, y_m) היא:

$$h(\mathbf{x}) = \sqrt{(x_m - x_s)^2 + (y_m - y_s)^2} \quad (20)$$

היעקוביאנים של פונקציה זו מחושבים בזמן אמת כדי לעדכן את מטריצת הקוריאנס של הרחפן.

VII. NAVIGATORCREW — עיצוב ומימוש הפלטפורמה

א'. סקירת הארכיטקטורה

פלטפורמת ה-NavigatorCrew היא מערכת מרובת-סוכנים (Multi-Agent System) המבוססת על פריימוורק ה-CrewAI. המערכת נועדה לבצע מחקר, סימולציה וכתובה של תכנים מדעיים בתחום הניווט האוטונומי בצורה אוטונומית לחלוטין.

ב'. הסוכנים במערכת

המערכת מורכבת מחמישה סוכנים מומחים:

- **מנהל המחקר (Research Director)**: אחראי על פירוק נושא המחקר לפרקים והנחיית שאר הסוכנים.
- **חוקר ה-SLAM והיתוך חיישנים**: מבצע חיפוש אקדמי ב-ArXiv ו-Serper ומחלץ אלגוריתמים ונוסחאות.
- **מהנדס היוזולאציה**: יוצר את הגרפים והדיאגרמות באמצעות קוד Python.
- **סופר ה-LaTeX**: מתרגם את ממצאי המחקר לקבצי XeLaTeX תקינים בעברית ובאנגלית.
- **עורך האיכות**: מבצע ביקורת עמיתים על המאמר, בודק עקביות מתמטית ודיוק בציטוטים.

ג'. הכלים (Tools) והזיכרון

הסוכנים מצוידים במערכת כלים המאפשרת להם אינטראקציה עם העולם החיצוני:

- **Search Tools**: חיפוש ב-ArXiv ו-Serper.dev.
- **Code Executor**: הרצת קוד Python בסביבה מאובטחת ליצירת גרפים.
- **File Tools**: קריאה וכתובה של קבצי טקסט ו-LaTeX.

המערכת משתמשת בזיכרון מבוסס ChromaDB (Vector DB) כדי לשמור על עקביות המידע בין הסוכנים לאורך כל שלבי המחקר. [?]

ד'. מימוש טכני ודיאגרמת המערכת

איור 5 (שנמצא בפרק III) מציג את זרימת המידע, בעוד שאיור 10 בפרק הבא יציג את תוצאות הריצה של המערכת. התשתית ממומשת ב-Python ורצה על גבי מעבדי NVIDIA Jetson עבור יישומי זמן-אמת ברחפנים.

VIII. תוצאות סימולציה וניתוח

א'. מדדי ביצוע (Metrics)

כדי להעריך את דיוק האלגוריתם, אנו משתמשים בשלושה מדדים סטנדרטיים בתחום ה-SLAM:

- (1) **Square Mean (Root RMSE): Error** מדד לשגיאה הממוצעת לאורך המסלול.
- (2) **Trajectory (Absolute ATE): Error** המרחק המוחלט בין המיקום המשוער למיקום האמת (Ground Truth).
- (3) **Pose (Relative RPE): Error** השגיאה בתנועה בין שני רגעים עוקבים.

ב'. ניתוח נתיב תלת-ממדי

באיור 9 מוצגת השוואה בין נתיב האמת לבין הנתיב שחושב על ידי אלגוריתם ה-BioSLAM בתוך מנהרה סינתטית. ניתן לראות כי האלגוריתם שומר על עקיבה הדוקה גם בתנאים של סיבובים חדים וחשיכה אקוסטית.

ב'. מגבלות

למרות התוצאות המבטיחות בסימולציה, קיימות מספר מגבלות:

- **רעש סביבתי:** השפעת רעשי רוח ומנועים על חיישני הסונאר דורשת מחקר נוסף בסינון רעשים אקטיבי.
- **חומרת זמן-אמת:** הטמעת המודלים של *Vision-AI* דורשת משאבי חישוב משמעותיים (GPU) שאינם זמינים תמיד ברחפנים זעירים.

ג'. כיוונים עתידיים

אנו מתכננים להרחיב את המחקר לניווט נחילים (*Swarm Navigation*) בהשראת להקות עטלפים, ולשלב מעבדים נוירומורפיים (*Neuromorphic Chips*) לשיפור יעילות האנרגיה.


ד'. מסקנות סופיות

השילוב בין בינה מלאכותית, רובוטיקה ועקרונות ביולוגיים פותח אופקים חדשים ליצירת מכונות אוטונומיות חכמות וחסינות יותר. פלטפורמת ה-*NavigatorCrew* מהווה צעד משמעותי לקראת מימוש חזון זה.

מקורות

[1] Kalman, E. R. "A Kalman, E. R. prediction and filtering linear to approach new". Engineering, Basic of Journal problems, 1960, 45--35 pp., 1 no., 82 vol.

חששה תמא
SLAM תכרעה
LIDAR תודוקנ ננע



איור 9: נתיב תלת-ממדי של הרחפן. הקו הכחול מייצג את אמת השטח והקו האדום המקווקו את הערכת המערכת.

ג'. תוצאות השוואתיות

השווינו את *BioSLAM* לשלושה אלגוריתמים מובילים: *EKF-SLAM*, *Graph-SLAM* ו-*ORB-SLAM3*.


אלגוריתם	$RMSE$ [ס"מ]	צריכת הספק $[W]$	זמן חישוב $[ms]$
<i>EKF-SLAM</i>	8.4	3.2	15
<i>Graph-SLAM</i>	5.1	4.5	45
<i>ORB-SLAM3</i>	3.8	6.1	120
<i>BioSLAM</i> (שלנו)	2.5	2.3	12

טבלה IV: סיכום ביצועים והשוואה לאלגוריתמי בסיס.

האלגוריתם המוצע מציג שיפור של 34% ב- $RMSE$ לעומת *ORB-SLAM3* וחסכון של 28% באנרגיה בהשוואה ל-*EKF-SLAM*.

ד'. סיכום ויזואלי של הביצועים

איור 10 מציג את התפלגות השגיאות לאורך זמן ואת היציבות של המערכת בתרחישים שונים.



איור 10: סיכום תוצאות הלוקליזציה: (א) $RMSE$ לאורך זמן, (ב) שגיאת ATE במטרים, (ג) התפלגות RPE .

IX. סיכום, מגבלות ועתיד

א'. תרומות המחקר

בעבודה זו הצגנו את *NavigatorCrew*, מערכת מרובת-סוכנים לניווט ומימוש ניווט ביומימטי לרחפנים. הוכחנו כי אימוץ עקרונות אקולוקציה מעולם העטלפים, בשילוב עם אלגוריתמי *SLAM* מודרניים והיתוך חיישנים רב-מודאלי, מאפשר דיוק גבוה וצריכת אנרגיה נמוכה בסביבות מורכבות.