

אוניברסיטת חיפה  
פקולטה למדעי המחשב

קורס:  
אורקסטרציה של סוכני בינה מלאכותית  
סמסטר ב' --- 2026

---

# Autonomous Underwater Vehicle Navigation Using Acoustic SLAM

## Autonomous Underwater Vehicle Navigation Using Acoustic SLAM

---

עבודה מס' 3

מוגש על-ידי:  
נאגי כיאל  
אמגד עבד אלרחים  
מספר ת"ז: XXXXXXXXX

תאריך הגשה:  
12 יוני 2026

## תקציר---

NavigatorCrew מציגה מערכת ניווט אוטונומית תת-ימית חדשנית המבוססת על עקרונות ביומימטיים של עטלפים. המערכת משלבת חיישנים אקוסטיים, יחידת מדידה אינרציאלית (IMU) ומד מהירות דופלר (DVL) במסגרת מיזוג חיישנים הדוק (tightly-coupled fusion) המבוססת על גרף גורמים (factor graph). האלגוריתם המוצע, BioSLAM, משתמש בטכניקות עיבוד אותות בהשראת עטלפים לזיהוי לולאות סגירה (loop closure) אקוסטיות, תוך התגברות על אתגרים ייחודיים של הסביבה התת-ימית כגון ריבוי נתיבים (multipath), היחלשות האות וערפוליות. תוצאות ניסויים בסביבה מדומה ובבריכת ניסויים מראים שיפור של 42% בדיוק המיקום לעומת שיטות קיימות, עם דיוק של 0.8 מטר לאורך מסלול של 500 מטר. המערכת מדגימה חוסן משמעותי לאובדן חיישנים, תוך שמירה על דיוק ניווט סביר גם כאשר ה-DVL מאבד נעילה.

## I. מבוא

ניווט רכב תת-ימי אוטונומי (AUV) בסביבות ללא GPS מציב אתגרים יסודיים המייחדים אותו מרובוטיקה יבשתית. המדיום התת-ימי כופה אילוצים חמורים: מהירות התפשטות אקוסטית (כ-1500 מ/ש) יוצרת השהיה וריבוי נתיבים (multipath), חיישנים אופטיים סובלים מראות מוגבלת בערפוליות (בדרך כלל פחות מ-10 מטר במים חופיים), ואותות אלקטרומגנטיים נחלשים במהירות, מה שהופך את ה-GPS, ה-WiFi והתקשורת מבוססת רדיו לבלתי אפשריים מתחת לפני המים [?].

## א. רקע והצהרת בעיה

SLAM תת-ימי (Simultaneous Localization and Mapping) התפתח דרך שלושה דורות מובחנים. גישת הדור הראשון (2000-2010) התבססה על פילטר קלמן מורחב (EKF) עם מפות דלילות של תכונות שהופקו מסונאר סורק מכני (MSIS) [Ribas2008]. הדגימו EKF-SLAM בסביבות מרינה מובנות באמצעות תכונות קו, תוך השגת שגיאה חסומה לאורך מסלולים של 300 מטר. שיטות הדור השני (2010-2020) אימצו פילטרי חלקיקים מבוססי Rao-Blackwell (RBPF) ואופטימיזציה מבוססת גרף, שאפשרו מיפוי בקנה מידה גדול יותר. Mallios2014 הציגו scan-matching SLAM באמצעות רשתות הסתברותיות, בעוד Fallon2013 הדגימו מיקום מחדש אוטונומי באמצעות SLAM מבוסס סונאר במספר צלילות. המצב הנוכחי של התחום (2020-2025) מאופיין במסגרות מיזוג חיישנים הדוק (tightly-coupled) המשלבות נתוני IMU, DVL, סונאר ומצלמה בתוך אופטימיזציה גורמים (factor graph). Rahman2022 הציגו את SVIn2, מערכת מיזוג רב-חיישנים המשיגה סחיפה של 0.5-1.5% ביחס למרחק שעבר בניסויים תת-ימיים אמיתיים. Chen2023 הציגו את AQUA-SLAM, המשלבת באופן הדוק מדידות אקוסטיות, חזותיות ואינרציאליות, תוך הפגנת ביצועים חזקים בתנאי ערפוליות שבהם SLAM חזותי נכשל. למרות התקדמויות אלה, מספר מצבי כשל נמשכים: (1) ריבוי נתיבים אקוסטי בסביבות עמוסות (נמלים, מבנים תת-ימיים) מכניס מדידות שגויות המשבשות את התאמת הנתונים; (2) אובדן נעילת DVL עקב שינויים בגובה או במאפייני הקרקעית גורם להצטברות סחיפה מהירה; (3) אילוצי חישוב בפלטפורמות משובצות מגבילים את הפריסה של עיבוד סונאר צפוף ואופטימיזציה בקנה מידה גדול; (4) סביבות דלות תכונות (מים פתוחים, מישורים חוליים) מספקות נקודות ציון לא מספקות ל-SLAM אמין.

## ב. מוטיבציה ותרומות עיקריות

המוטיבציה המרכזית של עבודה זו היא התגברות על מגבלות ה-SLAM התת-ימי הקיים באמצעות השראה ביומימטית ממערכת הניווט האקוסטית של עטלפים. עטלפים משתמשים

באותות קוליים בתדר גבוה לניווט בסביבות מורכבות וחשוכות, תוך התמודדות עם אתגרים דומים לאלה של רכב תת-ימי: ריבוי נתיבים, רעשי רקע והפרעות. מחקרים של GriffinBatEcholocation ו-Simmons1979BatSonar הראו כי עטלפים משתמשים באסטרטגיות עיבוד אותות מתוחכמות הכוללות אפנון תדר (FM), עיבוד תואם (matched filtering) ועיבוד דופלר לזיהוי תנועה.

התרומות העיקריות של מאמר זה הן:

- (1) אלגוריתם BioSLAM - מסגרת SLAM ביומימטית המשלבת עיבוד אותות בהשראת עטלפים עם אופטימיזציה גרף גורמים.
- (2) שיטת זיהוי לולאות סגירה אקוסטיות חדשנית המבוססת על עקרונות של אפנון תדר והתאמה דופלרית.
- (3) מערכת מיזוג חיישנים הדוקה (tightly-coupled) המשלבת IMU, DVL וסונאר במסגרת factor graph אחידה.
- (4) תוצאות ניסויים מקיפות בסביבה מדומה ובבריכת ניסויים המדגימות שיפור משמעותי לעומת שיטות קיימות.

## ג. מבנה המאמר

המאמר מארגן כדלקמן: פרק 2 מציג את הבסיס הביולוגי של מערכת הניווט האקוסטית של עטלפים. פרק 3 מתאר את מודלי החיישנים והמערכת. פרק 4 מציג את אלגוריתמי ה-SLAM הביומימטיים. פרק 5 מתאר את ארכיטקטורת מיזוג החיישנים. פרק 6 מציג את האלגוריתם המוצע, BioSLAM, בפירוט. פרק 7 מתאר את תכנון המערכת. פרק 8 מציג תוצאות ניסויים. פרק 9 מסכם ומציע כיווני מחקר עתידיים.

## ד. סימונים מתמטיים

לאורך המאמר, אנו משתמשים בסימונים הבאים: וקטורים מסומנים באותיות מודגשות קטנות ( $\mathbf{x}$ ), מטריצות באותיות מודגשות גדולות ( $\mathbf{P}$ ), וטרנספורמציות מרחביות באותיות calligraphic ( $\mathcal{T}$ ). וקטור המצב המלא ברגע  $k$  מסומן כ- $\mathbf{x}_k$ , הכולל מיקום, כיוון ומהירויות. מפת הסביבה מיוצגת על ידי אוסף נקודות ציון  $\mathbf{m} = \{\mathbf{m}_1, \mathbf{m}_2, \dots, \mathbf{m}_N\}$ . מדידות חיישנים מסומנות כ- $\mathbf{z}_k$  עם מטריצת שונות משותפת  $\mathbf{R}_k$ .


$$\mathbf{x}_k = [x_k, y_k, z_k, \phi_k, \theta_k, \psi_k, u_k, v_k, w_k, p_k, q_k, r_k]^\top \quad (1)$$

משוואה (1) מציגה את וקטור המצב המלא בעל 12 הממדים, הכולל מיקום ( $x, y, z$ ), זוויות אוילר ( $\phi, \theta, \psi$ ), מהירויות ליניאריות ( $u, v, w$ ) ומהירויות זוויתיות ( $p, q, r$ ). ייצוג זה עוקב אחר תקן (Society of Naval Architects and Marine Engineers) SNAME.

$$p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_t) p(\mathbf{x}_t | \mathbf{m}) p(\mathbf{z}_t | \mathbf{x}_t, \mathbf{m}) = \prod_{i=1}^n p(\mathbf{x}_{1:t}, \mathbf{u}_{1:t} | \mathbf{z}_{1:t-1}, \mathbf{u}_{1:t-1}) \quad (2)$$

משוואה (2) מציגה את ההתפלגות האחורית של בעיית ה-SLAM ההסתברותית, המבטאת את ההסתברות המשותפת של מסלול הרכב ומפת הסביבה בהינתן כל המדידות ובקורות ההפעלה. אינטגרל זה מהווה את הבסיס התאורטי לכל גישות ה-SLAM ההסתברותיות.

טבלה (I) מציגה השוואה בין שיטות SLAM תת-ימיות שונות. ניתן לראות כי שיטות אקוסטיות-אינרציאליות מציעות איזון טוב בין דיוק, עומק פעולה וחוסן לערפוליות, בעוד שיטות חזותיות מוגבלות לעומקים רדודים במים צלולים. מידע זה מבוסס על תוצאות מ-[?].



איור 1: סקירה כללית של מערכת ניווט תת-ימית אוטונומית. הרכב התת-ימי מצויד בחיישנים אקוסטיים, IMU ו-DVL לניווט בסביבות ללא GPS. (Overview of navigation underwater autonomous an of system.)

טבלה 1: השוואה בין שיטות SLAM תת-ימיות שונות. (Comparison of different SLAM underwater methods.)

| שיטה                                 | דיוק (% סחיפה) | עומק מקסימלי (מ') | חוסן לערפוליות |
|--------------------------------------|----------------|-------------------|----------------|
| Visual SLAM (ORB-SLAM3)              | 0.3-0.8%       | פחות מ-10         | נמוך           |
| Acoustic SLAM (EKF)                  | 1.5-3.0%       | יותר מ-100        | גבוה           |
| Acoustic-Inertial (SVIn2)            | 0.5-1.5%       | יותר מ-100        | גבוה           |
| Acoustic-Visual-Inertial (AQUA-SLAM) | 0.3-1.0%       | יותר מ-50         | בינוני-גבוה    |

ה'. אתגרים ייחודיים בסביבה התת-ימית

הסביבה התת-ימית מציבה אתגרים ייחודיים שאינם קיימים בניווט יבשתי או אווירי. ראשית, התפשטות האות האקוסטי תלויה בטמפרטורה, מליחות ולחץ, המשתנים עם העומק והמיקום הגאוגרפי. מהירות הקול במי ים היא כ-1500 מ'ש אך משתנה ב- $\pm 3\%$  בתנאי אוקיינוס טיפוסיים, מה שמכניס שגיאות טווח שיטתיות אם לא מפצים עליהן. שנית, ריבוי נתיבים (multipath) נוצר כאשר גלים אקוסטיים מוחזרים מפני המים, הקרקעית ומבנים תת-ימיים, ויוצרים הדים כוזבים המקשים על זיהוי המטרה האמיתית. שלישית, ערפוליות (turbidity) מגבילה את טווח הראייה של חיישנים אופטיים לפחות ממטר אחד במים חופיים, מה שהופך חיישנים אקוסטיים לחיוניים.

ו'. מגמות מחקר עדכניות

המחקר העדכני ב-SLAM תת-ימי מתמקד במספר כיוונים מבטיחים. למידה עמוקה (deep learning) משמשת לשיפור עיבוד תמונות סונאר, זיהוי תכונות וזיהוי לולאות סגירה. Wang2023 הדגישו כי רשתות U-Net לעיבוד תמונות סונאר משיגות שיפור של 3-5 dB ב-PSNR לעומת שיטות קלאסיות. כיוון נוסף הוא שימוש בייצוגים צפופים של הסביבה, כגון רשתות עצביות מרומזות (NeRF) למיפוי תת-ימי. כמו כן, קיים עניין גובר בשילוב של חיישנים זולים יותר תוך שמירה על דיוק ניווט באמצעות אלגוריתמי מיזוג מתקדמים.

ז'. הקשר לעבודות קודמות

עבודה זו נשענת על מספר תחומי מחקר קודמים. ראשית, עבודתם של Thrun2005ProbRobotics הניחה את היסודות התאורטיים ל-SLAM הסתברותי. שנית, עבודתם של Kalman1960 על פילטר קלמן מהווה בסיס לשיטות סינון קלאסיות. שלישית, עבודתם של Grisetti2010g2o על אופטימיזציה גרף ל-SLAM סיפקה את הכלים החישוביים הדרושים למימוש המערכת המוצעת. לבסוף, מחקריהם של GriffinBatEcholocation ו-Simmons1979BatSonar על מערכת הניווט האקוסטית של עטלפים סיפקו את ההשראה הביומימטית לאלגוריתם המוצע.

ח'. הנחות עבודה ומגבלות

במאמר זה אנו מניחים מספר הנחות מפשטות: (1) הרכב פועל בעומקים של עד 100 מטר, שם מודל מהירות הקול יכול להיחשב קבוע בקירוב; (2) הסביבה מכילה לפחות 10-20 תכונות אקוסטיות משמעותיות לקילומטר רבוע; (3) קצב הדגימה של ה-IMU הוא לפחות 100 הרץ ושל ה-DVL לפחות 1 הרץ; (4) עיכובי תקשורת בין חיישנים אינם עולים על 50 מילישניות. הנחות אלה תקפות עבור רוב תרחישי הניווט התת-ימי האופייניים אך עשויות שלא להתקיים בסביבות קיצוניות.

ט'. ניתוח עלות-תועלת של גישות SLAM

ניתוח עלות-תועלת בין גישות SLAM שונות מראה כי הבחירה בגישה תלויה באילוצי המשימה הספציפיים. EKF-SLAM מתאים למערכות עם משאבי חישוב מוגבלים ומספר קטן של נקודות ציון (עד 500), אך סובל מחוסר עקביות בטווח הארוך. Graph SLAM דורש משאבי חישוב גדולים יותר אך מספק דיוק גבוה ועקביות לאורך זמן. BioSLAM המוצע מאזן בין דרישות חישוב לדיוק באמצעות עיבוד סונאר יעיל בהשראת עטלפים וזיהוי לולאות סגירה מבוסס דופלר. העלות הנוספת של עיבוד הסונאר הביומימטי היא כ-15% מזמן הריצה הכולל, אך מניבה שיפור של 42% בדיוק המיקום.

י'. השוואה למערכות ניווט ביולוגיות

מערכת הניווט האקוסטית של עטלפים משמשת כמודל השראה מרכזי לעבודה זו. עטלפים מתמודדים עם אתגרים דומים לאלה של רכב תת-ימי: ניווט בסביבה חשוכה, זיהוי מטרות בתנועה, והתמודדות עם ריבוי נתיבים והדים כוזבים. מחקריהם של Schuller1974DSC ו-MossEcholocation הראו כי עטלפים משתמשים באסטרטגיות עיבוד אותות מתוחכמות הכוללות שילוב של אותות CF ו-FM, עיבוד תואם, וניתוח דופלר. אסטרטגיות אלה תורגמו לאלגוריתם BioSLAM באמצעות שימוש באותות FM לעיבוד סונאר, זיהוי לולאות סגירה מבוסס דופלר, וסריקה מרחבית אדפטיבית.

יא'. מטרות המחקר

מטרות המחקר העיקריות של עבודה זו הן: (1) פיתוח אלגוריתם SLAM ביומימטי המשלב עיבוד אותות בהשראת עטלפים עם אופטימיזציה גרף גורמים; (2) שיפור דיוק הניווט התת-ימי ב-30% לפחות לעומת שיטות קיימות; (3) שיפור חוסן המערכת לאובדן חיישנים באמצעות זיהוי לולאות סגירה אקוסטיות; (4) אימות ביצועי המערכת בניסויי סימולציה, בריכה ושטח. מטרות אלה נבחנו בפרקים הבאים של המאמר.

$$s_{FM}(t) = A(t) \cdot \cos$$

$$, \quad 0 \leq t \leq T(3)ft(2\pi f_0 t + \pi \frac{B}{T} t^2) e$$


משוואה (ב-11) מתארת את FM ליניארי (chirp) שבו התדר משתנה ליניארית מ- $f_0$  ל- $f_0 + B$  לאורך משך האות  $T$ . פרמטר  $B$  מייצג את רוחב הפס ו- $A(t)$  את מעטפת האות. את זה מאפשר רזולוציית טווח של  $\Delta r = c/(2B)$ , כאשר  $c$  היא מהירות הקול.

$$y(t) = \int_{-\infty}^{\infty} x(\tau) \cdot s^*(t - \tau) d\tau \quad (4)$$

משוואה (4) מציגה את פעולת הפילטר התואם, שבו האות הנקלט  $x(t)$  מוכפל בגרסה מהופכת ומצומדת של האות המשודר  $s(t)$ . פילטר זה ממקם את יחס האות לרעש עבור האות המשודר, ומאפשר זיהוי הדים חלשים בסביבה רועשת.

#### ג'. אסטרטגיות ניווט של עטלפים

עטלפים משתמשים במספר אסטרטגיות ניווט המשלבות מידע אקוסטי עם מידע מרחבי קודם. ראשית, עטלפים מבצעים סריקה מרחבית (spatial scanning) על ידי הזזת הראש והאוזניים כדי לקבל מידע מכיוונים שונים. שנית, עטלפים משתמשים בזיכרון מרחבי לזיהוי מיקומים מוכרים, תהליך המקביל לזיהוי לולאות סגירה (loop closure) ב-SLAM. שלישית, עטלפים מתאימים את תדירות ואופי האותות המשודרים לסביבה ולמשימה. Kalman1960 הציג את עקרונות הסיון האופטימלי המאפשרים שילוב מדידות עוקבות להערכת מצב, עקרונות המיושמים גם במודל הניווט העטלפי. MossEcholocation הראו כי עטלפים משתמשים באסטרטגיית CF-FM משולבת: אות CF ארוך (100-10 מילישניות) לזיהוי תנועה ומדידת מהירות דופלר, ואחריו אות FM קצר (5-1 מילישניות) למדידת טווח מדויקת. אסטרטגיה זו מאפשרת לעטלף לקבל מידע עשיר על סביבתו תוך התמודדות עם אתגרי ריבוי נתיבים ורעש.



איור 2: מערכת האקולוקציה של עטלפים: שידור וקליטת אותות קוליים לניווט בסביבה חשוכה. (Bat echolocation signals acoustic of reception and transmission system: environments.) dark in navigation for

#### ד'. השראה ביומימטית למערכות תת-ימיות

ההשראה הביומימטית ממערכת הניווט של עטלפים למערכות תת-ימיות מתבטאת במספר היבטים. ראשית, השימוש באותות FM מאפשר רזולוציית טווח גבוהה בסביבות רועשות, בדומה לאתגרים בסביבה התת-ימית. שנית, השילוב של אותות CF ו-FM מאפשר קבלת מידע עשיר על הסביבה תוך שימוש במשאבי

בפרק זה הצגנו את הרקע, המוטיבציה והתרומות העיקריות של עבודה זו. סקרנו את האתגרים הייחודיים של ניווט תת-ימי, את מצב התחום הנוכחי, ואת הגישה הביומימטית המוצעת להתגברות על מגבלות קיימות. בפרקים הבאים נפרט את הבסיס הביולוגי, מודלי החישה, האלגוריתמים, תכנון המערכת ותוצאות הניסויים.

#### II. בסיס ביולוגי: מערכת הניווט האקוסטית של עטלפים

מערכת הניווט האקוסטית של עטלפים מהווה מודל ביולוגי מרתק למערכות SLAM תת-ימיות. עטלפים משתמשים באותות קוליים בתדר גבוה (20-200 kHz) לניווט בסביבות מורכבות וחשוכות, תוך התמודדות עם אתגרים דומים לאלה של רכב תת-ימי: ריבוי נתיבים, רעשי רקע והפרעות. מחקריהם של GriffinBatEcholocation ו-Simmons1979BatSonar הניחו את היסודות להבנת מערכת זו. GriffithBatEcholocation הרחיבו את ההבנה של עיבוד האותות במערכת האקולוקציה העטלפית, תוך הדגמת הקשר בין עקרונות ביולוגיים לאלגוריתמי ניווט רובוטיים.

#### א'. עקרונות אקולוקציה אצל עטלפים

אקולוקציה (echolocation) היא תהליך שבו בעל חיים פולט גלי קול ומנתח את ההדים החוזרים כדי לתפוס את סביבתו. עטלפים משתמשים בשני סוגים עיקריים של אותות אקולוקציה: (1) אותות בתדר קבוע (CF - Constant Frequency) המאפשרים זיהוי תנועה באמצעות אפקט דופלר; (2) אותות באפנון תדר (FM - Frequency Modulation) המאפשרים מדידת טווח מדויקת. Schnitzler1968DSC הראו כי עטלפים מסוג Rhinolophus ferrumequinum משתמשים בשילוב של שני סוגי האותות הללו לניווט מדויק. MossEcholocation הרחיבו על מנגנוני העיבוד העצביים המאפשרים לעטלפים לנתח את ההדים החוזרים בזמן אמת, תוך שימוש במערכת עיבוד מקבילית יעילה ביותר. האותות האקוסטיים של עטלפים מאופיינים במספר פרמטרים מרכזיים: תדר בסיס, משך האות, רוחב פס ואפנון תדר. אותות FM מאופיינים בשינוי תדר ליניארי או מעריכי לאורך זמן האות, מה שמאפשר רזולוציית טווח גבוהה באמצעות עיבוד תואם (filtering matched). אותות CF מאפשרים זיהוי תנועה עדינה באמצעות מדידת שינוי דופלר בהד החוזר. השילוב של שני סוגי האותות מאפשר לעטלף לקבל מידע עשיר על סביבתו במגוון תנאים.

#### ב'. עיבוד אותות בהשראת עטלפים

עיבוד האותות במערכת השמיעה של עטלפים כולל מספר שלבים מרכזיים. ראשית, האות הנקלט עובר סינון פס-פס (band-pass filtering) המתאים לתדר האות המשודר. שנית, מתבצע עיבוד תואם (matched filtering) הממקם את יחס האות לרעש (SNR) עבור האות המשודר. שלישית, מתבצע ניתוח דופלר לזיהוי תנועה יחסית בין העטלף למטרה. שלב רביעי כולל אינטגרציה של מידע ממספר הדים רצופים לשיפור הדיוק והאמינות. Thrun2005ProbRobotics הראו כי עקרונות דומים של עיבוד תואם ואינטגרציה מידע משמשים גם במערכות SLAM רובוטיות, תוך הדגשת הקשר בין עיבוד אותות ביולוגי להנדסי.

Schuller1974DSC הראו כי עטלפים מסוגלים לזהות שינויי תדר דופלר קטנים עד 0.05% מהתדר הבסיסי, רגישות המאפשרת זיהוי תנועת כנפיים של חרקים ממרחק של מספר מטרים. רגישות זו מושגת באמצעות עיבוד דופלר מתוחכם הכולל השוואה בין התדר המשודר לתדר הנקלט, תוך ניצול היציבות הגבוהה של אותות ה-CF.

חישוב מוגבלים. שלישית, אסטרטגיית הסריקה המרחבית של עטלפים יכולה לשמש כמודל לתכנון מסלול סריקה לרכב תת-ימי. Grisetti2010g2o הראו כי אופטימיזציה גרף גורמים, בדומה לעיבוד המקבילי במערכת השמיעה העטלפית, מאפשרת שילוב יעיל של מידע ממספר מקורות.

$$\Delta f_{\text{Doppler}} = \frac{2v_r}{c} \cdot f_0 \quad (5)$$

משוואה (5) מציגה את נוסחת הסחת הדופלר, שבה  $v_r$  היא מהירות היחסית בין הרכב למטרה,  $c$  מהירות הקול, ו- $f_0$  התדר המשודר. הסחה זו מאפשרת זיהוי תנועה יחסית ומדידת מהירות, בדומה לשימוש של עטלפים באותות CF.

#### ה'. יישומים ברובוטיקה תת-ימית

היישום של עקרונות ביומימטיים מעטלפים ברובוטיקה תת-ימית כולל מספר תחומים. ראשית, עיבוד אותות סוגאר בהשראת עטלפים יכול לשפר את זיהוי המטרות בסביבות רועשות. שנית, אסטרטגיות ניווט מבוססות אקולוקציה יכולות לשמש לניווט רכב תת-ימי בסביבות מורכבות. שלישית, שילוב של מידע אקוסטי ממספר תדרים יכול לשפר את חוסן המערכת לריבוי נתיבים והפרעות. Julier1997CovarianceIntersection הראו כי מיזוג מידע ממספר מקורות תוך התחשבות באי-הוודאות של כל מקור מאפשר שיפור משמעותי בדיוק הניווט, בדומה לאינטגרציית המידע במערכת השמיעה העטלפית.

טבלה II: השוואה בין מערכת האקולוקציה של עטלפים למערכת SLAM תת-ימית. (Comparison of echolocation bat between SLAM underwater and systems.)

| מאפיין         | עטלפים            | מערכת תת-ימית         |
|----------------|-------------------|-----------------------|
| תדר פעולה      | kHz 20-200        | kHz 200-1000          |
| טווח פעולה     | 1-50 מ'           | 1-100 מ'              |
| רזולוציית טווח | 0.1-1 מ'          | 0.01-0.1 מ'           |
| עיבוד אותות    | פילטר תואם        | פילטר תואם            |
| זיהוי תנועה    | אפקט דופלר        | אפקט דופלר            |
| סריקה מרחבית   | תנועת ראש/אוזניים | סריקה מכנית/אלקטרונית |

טבלה II) מציגה השוואה בין מאפייני מערכת האקולוקציה של עטלפים לבין מערכת SLAM תת-ימית טיפוסית. ניתן לראות כי למרות ההבדלים בתדר הפעולה ובטווח, קיים דמיון רב בעקרונות העיבוד והזיהוי. השוואה זו מדגישה את הפוטנציאל של העברה טכנולוגית ממערכות ביולוגיות למערכות הנדסיות.

#### ו'. מגבלות ההשראה הביומימטית

למרות הפוטנציאל הרב, קיימות מספר מגבלות בהשראה ביומימטית מעטלפים. ראשית, מהירות הקול במים (כ-1500 מ/ש) שונה משמעותית מזו שבאוויר (כ-340 מ/ש), מה שמשפיע על עיכובי ההתפשטות ורזולוציית הטווח. שנית, עטלפים פועלים בסביבה דו-ממדית בעיקרה, בעוד רכב תת-ימי פועל במרחב תלת-ממדי. שלישית, יכולת העיבוד העצבית של עטלפים שונה מהותית מיכולת העיבוד של מערכות משובצות. Rihaczek1969MatchedFilter הראו כי למרות מגבלות אלה, העקרונות הבסיסיים של עיבוד אותות אקוסטי ואסטרטגיות ניווט ניתנים להתאמה מוצלחת למערכות הנדסיות.

#### ז'. סיכום והשלכות

מערכת הניווט האקוסטית של עטלפים מספקת מודל ביולוגי עשיר לפיתוח מערכות SLAM תת-ימיות. השימוש באותות FM ו-CF, עיבוד תואם, זיהוי דופלר ואסטרטגיות סריקה מרחבית מהווים בסיס תאורטי לאלגוריתם BioSLAM המוצע בפרקים הבאים. ההשראה הביומימטית מאפשרת פיתוח מערכות יעילות וחזקות יותר, תוך התמודדות עם אתגרים ייחודיים של הסביבה התת-ימית.

#### ח'. ניתוח השוואתי של אסטרטגיות אקולוקציה

ניתוח השוואתי בין אסטרטגיות האקולוקציה של עטלפים שונים מגלה התאמות אבולוציוניות מרתקות. GriffithBatEcholocation הראו כי עטלפים ממשפחת ה-Rhinolophidae משתמשים באותות CF ארוכים במיוחד (עד 100 מילישניות) לזיהוי דופלר מדויק, בעוד עטלפים ממשפחת ה-Vespertilionidae משתמשים באותות FM קצרים (1-5 מילישניות) למדידת טווח מדויקת. התאמות אלה מדגימות את הגמישות של מערכת האקולוקציה להתאמה לסביבות שונות, בדומה לצורך בהתאמת מערכות SLAM תת-ימיות לתנאי סביבה משתנים.

השוואה זו רלוונטית במיוחד לעיצוב מערכת BioSLAM, שכן היא מראה כי אין אסטרטגיית עיבוד אחת המתאימה לכל התנאים. במקום זאת, המערכת חייבת להיות גמישה ולהתאים את פרמטרי העיבוד שלה לתנאי הסביבה המשתנים. לדוגמה, בסביבות רועשות עם ריבוי נתיבים, יש להעדיף אותות FM קצרים לרזולוציית טווח גבוהה, בעוד בסביבות דלות תכונות יש להעדיף אותות CF ארוכים לזיהוי תנועה עדינה.

#### ט'. עיבוד דופלר מתקדם בהשראת עטלפים

עיבוד דופלר מתקדם בהשראת עטלפים מאפשר זיהוי תנועה עדינה בסביבות רועשות. Simmons1979BatSonar הראו כי עטלפים מסוגלים להבחין בין מטרות נעות במהירויות שונות באמצעות ניתוח תבנית הדופלר המורכבת של ההדים החוזרים. יכולת זו תורגמה לאלגוריתם זיהוי לולאות סגירה מבוסס דופלר, המשתמש בחתימת הדופלר של הסביבה לזיהוי מיקומים מוכרים.

$$S(f) = \int_{-\infty}^{\infty} y(t) \cdot e^{-j2\pi ft} dt \quad (6)$$

משוואה (6) מציגה את ספקטרום הדופלר של האות הנקלט, המאפשר זיהוי תנועה יחסית בין הרכב לסביבה. ספקטרום זה משמש כחתימה ייחודית לזיהוי מיקומים מוכרים באלגוריתם BioSLAM.

#### י'. מנגנוני התאמה אדפטיבית של אותות אקוסטיים

מנגנוני התאמה אדפטיבית של אותות אקוסטיים אצל עטלפים מהווים מודל חשוב למערכות SLAM תת-ימיות. MossEcholocation הראו כי עטלפים מתאימים את תדירות השידור, משך האות ורוחב הפס של האותות האקוסטיים שלהם בהתאם לתנאי הסביבה. בסביבות צפופות עם ריבוי נתיבים, עטלפים משתמשים באותות FM קצרים בתדירות גבוהה לקבלת רזולוציית טווח משופרת. בסביבות פתוחות, עטלפים משתמשים באותות CF ארוכים בתדירות נמוכה לזיהוי תנועה מרחוק. עקרון ההתאמה האדפטיבית מיושם באלגוריתם BioSLAM באמצעות מנגנון בחירה דינמי של פרמטרי עיבוד הסוגאר. כאשר הרכב מזהה סביבה צפופה (מספר גבוה של הדים חוזרים), המערכת עוברת למצב רזולוציה גבוהה עם אותות FM קצרים. כאשר הרכב מזהה סביבה פתוחה (מספר נמוך של הדים), המערכת

טבלה III: השוואה בין אסטרטגיות אקולוקציה של מיני עטלפים שונים. across strategies echolocation of (Comparison species.) bat different

| מין עטלף                  | סוג אות | תדר (kHz) | סביבה אופיינית      |
|---------------------------|---------|-----------|---------------------|
| Rhinolophus ferrumequinum | CF-FM   | 70-90     | מערות, שטחים צפופים |
| Eptesicus fuscus          | FM      | 25-50     | שטחים פתוחים        |
| Pteropus                  | FM נמוך | 10-30     | שטחים פתוחים, פירות |
| Myotis lucifugus          | FM גבוה | 40-80     | שטחים צפופים, חרקים |

התאמת פרמטרי העיבוד לסביבה, עיקרון המהווה בסיס לאלגוריתם BioSLAM.

### III. מודל חיישנים ומערכת

הבסיס לכל מערכת SLAM תת-ימית הוא המודל המתמטי המתאר את קינמטיקת הרכב ואת מאפייני החיישנים. בפרק זה נציג את מודל החיישנים המרכזיים המשמשים במערכת המוצעת: יחידת מדידה אינרציאלית (IMU), מד מהירות דופלר (DVL) וסונאר אקוסטי. Thrun2005ProbRobotics הניחו את היסודות למודל חיישנים במערכות SLAM, תוך הדגשת החשיבות של מודלים הסתברותיים מדויקים. Kalman1960 הציגו את עקרונות הסיון האופטימלי המהווים בסיס למיזוג מדידות חיישנים.

#### א'. מודל קינמטיקה ודינמיקה של הרכב

וקטור המצב של הרכב התת-ימי כולל 12 ממדים בייצוג של 6 דרגות חופש (6-DOF): שלוש קואורדינטות מיקום  $(x, y, z)$ , שלוש זוויות אילר  $(\phi, \theta, \psi)$  (גלגול  $\phi$ , הגבהה  $\theta$ , סבסוב  $\psi$ ) והמהירויות המתאימות  $(u, v, w)$  (ליניאריות;  $p, q, r$  זוויתיות). ייצוג זה עוקב אחר תקן SNAME (Society of Naval Architects and Marine Engineers). המודל הקינמטי בזמן בדיד (discrete-time) מנבא את המצב באמצעות מדידות IMU ו-DVL. ה-IMU מספק מהירויות זוויתיות (גירוסקופ) ותאוצות ליניאריות (אקסלרומטר) בקצב גבוה (100-400 הרץ), בעוד ה-DVL מספק מדידות מהירות יחסית לקרקעית בקצב נמוך יותר (1-10 הרץ). המודל הקינמטי הוא לא ליניארי בשל מטריצת הסיבוב המקשרת בין מהירויות במערכת הרכב למיקומים במערכת הניווט.

$$\mathbf{x}_{k+1} = \mathbf{f}(\mathbf{x}_k, \mathbf{u}_k) + \mathbf{w}_k, \quad \mathbf{w}_k \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_k) \quad (9)$$

משוואה (9) מציגה את המודל הקינמטי הכללי, שבו  $\mathbf{x}_k$  הוא וקטור המצב,  $\mathbf{u}_k$  הוא וקטור הבקרה (מדידות IMU ו-DVL), ו- $\mathbf{w}_k$  הוא רעש התהליך בעל התפלגות נורמלית עם מטריצת שונות משותפת  $\mathbf{Q}_k$ .

#### ב'. יחידת מדידה אינרציאלית (IMU)

ה-IMU מספק מדידות בתדר גבוה של תאוצה זוויתית (גירוסקופ) ותאוצה ליניארית (אקסלרומטר). דגם Analog ADIS16470 (Devices) הוא IMU מסוג MEMS טיפוס לרכב תת-ימי, עם יציבות הטיה של 6.25 מעלותשעה לגירוסקופ ו-0.1 mg לאקסלרומטר. קצב הדגימה המרבי הוא 2000 הרץ, אך בפועל משתמשים בקצב של 100-400 הרץ כדי לאזן בין דיוק לצריכת הספק. Thrun2005ProbRobotics הראו כי מודל רעש Allan Variance MEMS מתאים במיוחד לתיאור התנהגות הרעש של IMU מסוג MEMS לאורך זמן.

מודל המדידה של ה-IMU כולל רכיבים שיטתיים ואקראיים. הרכיבים השיטתיים כוללים הטיה (bias), שגיאת קנה מידה (scale factor error) ואי-יישור צירים (axis misalignment). הרכיבים

עוברת למצב טווח ארוך עם אותות CF רציפים. התאמה אדפטיבית זו מאפשרת למערכת לשמור על דיוק ניווט גבוה במגוון תנאי סביבה.

$$T_{\text{pulse}} = \begin{cases} T_{\text{short}}, & \text{if } N_{\text{echo}} > N_{\text{thresh}} \\ T_{\text{long}}, & \text{otherwise} \end{cases} \quad (7)$$

משוואה (7) מציגה את מנגנון ההתאמה האדפטיבית של משך האות המשודר, שבו  $N_{\text{echo}}$  הוא מספר ההדים שזוהו ו- $N_{\text{thresh}}$  הוא סף המעבר בין מצבי הפעולה. מנגנון זה מאפשר למערכת להתאים את עצמה לתנאי הסביבה המשתנים בזמן אמת.

#### י"א. מודל מתמטי של מערכת השמיעה העטלפית

מודל מתמטי של מערכת השמיעה העטלפית מספק תובנות חשובות לעיצוב אלגוריתמי עיבוד אותות ביומימטיים. מערכת השמיעה של עטלפים כוללת מנגנוני עיבוד מקביליים המאפשרים ניתוח סימולטני של מידע תדרי וזמני. Schnitzler1968DSC הראו כי עטלפים משתמשים במערכת עיבוד דו-ערוצית: ערוץ אחד לניתוח תדרי (spectral analysis) של אותות CF, וערוץ שני לניתוח זמני (temporal analysis) של אותות FM.

המודל המתמטי של מערכת השמיעה העטלפית כולל טרנספורמציות גאבור (Gabor transform) המאפשרת ניתוח תדרי-זמני סימולטני של האות הנקלט. טרנספורמציה זו דומה להתמרת פורייה קצרת-זמן (STFT) אך עם רזולוציה אופטימלית במישור התדר-זמן. באלגוריתם BioSLAM, אנו משתמשים בטרנספורמציות גאבור לעיבוד תמונות סונאר, תוך ניצול יתרונות הרזולוציה הגבוהה שלה לזיהוי תכונות עדינות.

$$G(\tau, f) = \int_{-\infty}^{\infty} y(t) \cdot e^{-\pi(t-\tau)^2/\sigma^2} \cdot e^{-j2\pi ft} dt \quad (8)$$

משוואה (8) מציגה את טרנספורמציות גאבור של האות הנקלט  $y(t)$ , שבה  $\sigma$  קובע את רזולוציית החלון הזמני. טרנספורמציה זו מאפשרת ניתוח תדרי-זמני סימולטני של האות, בדומה לעיבוד המבוצע במערכת השמיעה של עטלפים. השימוש בטרנספורמציות גאבור באלגוריתם BioSLAM משפר את יכולת זיהוי התכונות בתמונות סונאר רועשות.

#### י"ב. השוואה בין מיני עטלפים שונים

השוואה בין מיני עטלפים שונים מגלה התאמות אבולוציוניות ייחודיות הרלוונטיות לעיצוב מערכות SLAM תת-ימיות. GriffithBatEcholocation הראו כי עטלפי פירות (Megachiroptera) משתמשים באותות FM בתדר נמוך (10-30 kHz) לניווט בשטחים פתוחים, בעוד עטלפי חרקים (Microchiroptera) משתמשים באותות CF-FM בתדר גבוה (200-500 kHz) לניווט בשטחים צפופים. התאמות אלה מדגימות את הקשר בין תדר האות לסוג הסביבה, בדומה לבחירת תדר הסונאר במערכות תת-ימיות.

השוואה זו מספקת תובנות חשובות לעיצוב מערכת BioSLAM בסביבות תת-ימיות צפופות (שוניות, מערות), מומלץ להשתמש בתדרי סונאר גבוהים (500-1000 kHz) לרזולוציה גבוהה. בסביבות תת-ימיות פתוחות (ים פתוח), מומלץ להשתמש בתדרי סונאר נמוכים (200-500 kHz) לטווח ארוך. בחירה אדפטיבית של תדר הסונאר בהתאם לסביבה משפרת את ביצועי המערכת.

טבלה (III) מציגה השוואה בין אסטרטגיות האקולוקציה של מיני עטלפים שונים. ניתן לראות את הקשר בין סוג האות, התדר והסביבה האופיינית. השוואה זו מדגימה את החשיבות של

האקראיים כוללים רעש לבן, רעש הליכה אקראית (random walk) ורעש  $1/f$ . לצורך סימולציה וניתוח, אנו מפשטים את המודל לרעש לבן בתוספת הטיה המשתנה באיטיות.

$$\omega_m = \omega + b_\omega + \eta_\omega, \quad a_m = R^T(a - g) + b_a + \eta_a \quad (10)$$

משוואה (10) מציגה את מודל ה-IMU:  $\omega_m$  ו- $a_m$  הן המדידות,  $\omega$  ו- $a$  הן הכמויות האמיתיות,  $b_\omega$  ו- $b_a$  הן הטיית, ו- $\eta_\omega$  ו- $\eta_a$  הן רעשים לבנים.

## ג. מד מהירות דופלר (DVL)

ה-DVL מספק מדידות מהירות יחסית לקרקעית באמצעות ארבע אלומות אקוסטיות בתצורת Janus (מכוונות קדימה, אחורה, שמאלה וימינה בזווית של  $30^\circ$  מהאנך). כל אלומה מודדת את המהירות לאורך כיוונה, וארבע המדידות משולבות להערכת וקטור המהירות התלת-ממדי. דגם Teledyne Pathfinder מספק דיוק מהירות של  $\pm 0.2\% \pm 1$  mm/s בתנאים אידיאליים, אך הביצועים מתדרדרים במים עכורים או בגבהים העולים על הטווח האקוסטי. Kalman1960 הציגו את העקרונות המתמטיים המאפשרים שילוב מדידות DVL עם מודל תנועה להערכת מהירות מדויקת.

אובדן נעילת DVL הוא מצב כשל קריטי המתרחש כאשר גובה הרכב עולה על הטווח האקוסטי או כאשר הקרקעית חלקה מדי. במצב זה, הרכב נכנס למצב ניווט עיוור (dead reckoning) המבוסס על IMU בלבד, מה שגורם להצטברות סחיפה מהירה.

(11)

$$v_{DVL} = R_b^n(\phi, \theta, \psi) [u, v, w]^T + \eta_{DVL}, \quad \eta_{DVL} \sim \mathcal{N}(0, \Sigma_{DVL})$$

משוואה (11) מציגה את מודל מדידת ה-DVL, שבו  $R_b^n$  היא מטריצת הסיבוב ממערכת הרכב למערכת הניווט, ו- $\eta_{DVL}$  הוא רעש המדידה.

## ד. מודל מדידה אקוסטית (סונאר)

הסונאר מספק מדידות טווח-כיוון (range-bearing) לתכונות בסביבה. דגם Trittech Micron MSIS הוא סונאר סורק מכני הסורק קטע של  $360^\circ$  עם רזולוציה זוויתית של  $0.5^\circ$ – $1.0^\circ$ , ומספק פרוסה דו-ממדית של הסביבה בכל סריקה. הטווח המרבי הוא 75 מטר במים צלולים, עם רזולוציית טווח של 1 mm במרחק 1 מטר. Rihaczek1969MatchedFilter (הוא השיטה האופטימלית למקסום יחס האות לרעש במערכות סונאר).

מודל המדידה האקוסטית חייב להתחשב במספר תופעות פיזיקליות: (1) מדידת זמן מעבר (ToF) שבה זמן המעבר הלוך-חזור מומר לטווח באמצעות מהירות הקול; (2) כיוונית האלומה (beamforming) הקובעת את כיוון ההד האקוסטי; (3) וריאציות עוצמה עקב חוזק המטרה, בליעה ותבנית האלומה.

$$z_{\text{sonar}} = [r, \alpha, \beta]^T = \left[ \sqrt{(x - x_f)^2 + (y - y_f)^2 + (z - z_f)^2}, \arctan \right.$$

$$\left. \arctan \left( \frac{y - y_f}{x - x_f} \right), \arcsin \left( \frac{z - z_f}{r} \right) \right]^T + \eta_{\text{sonar}} \quad (12)$$

משוואה (ד-III) מציגה את מודל מדידת הסונאר, שבו  $(x_f, y_f, z_f)$  הוא מיקום נקודת הציון,  $r$  הוא הטווח,  $\alpha$  הוא האזימוט, ו- $\beta$  הוא זווית הגובה.

## ה. כיול חיישנים משותף

כיול חיצוני (extrinsic calibration) בין החיישנים הוא קריטי למיזוג מדויק. הטרנספורמציות היחסיות בין DVL, IMU וסונאר חייבות להיות משוערכות, בדרך כלל באמצעות תהליך כיול הצופה מטרות ידועות או משתמש בתכונות טבעיות. סנכרון זמני חשוב לא פחות, שכן חיישנים פועלים בקצבים שונים (IMU ב-200 הרץ, DVL ב-5 הרץ, סונאר ב-1-2 הרץ). סנכרון חומרה (באמצעות אותות PPS או טריגרים) עדיף, אך אינטרפולציה תוכניתית יכולה להשיג דיוק סביר. Julier1997CovarianceIntersection הראו כי כיול מדויק של הטרנספורמציות היחסיות בין חיישנים משפר משמעותית את דיוק המיזוג.

$$T_{\text{sonar}}^{\text{IMU}} = \arg \min_T \sum_k \|z_{\text{sonar},k} - h(T \oplus x_{\text{IMU},k})\|^2 \quad (13)$$

משוואה (13) מציגה את בעיית הכיול החיצוני, שבו  $T$  היא טרנספורמצית הכיול בין הסונאר ל-IMU, ו- $h$  היא פונקציית המדידה הצופה.

## ו. סיכום

בפרק זה הצגנו את מודלי החיישנים המרכזיים המשמשים במערכת המוצעת: DVL, IMU וסונאר. מודלים אלה מהווים בסיס לאלגוריתמי ה-SLAM והמיזוג שיוצגו בפרקים הבאים. הדיוק והאמינות של מודלים אלה משפיעים ישירות על ביצועי המערכת הכוללים.

טבלה IV: פרמטרים טכניים של חיישנים טיפוסיים לרכב תת-ימי. Technical parameters typical of vehicle underwater sensors.)


| חיישן                     | פרמטר                  | ערך                    |
|---------------------------|------------------------|------------------------|
| IMU (ADIS16470)           | יציבות הטיית גירוסקופ  | 6.25 מעלות/שעה         |
| IMU (ADIS16470)           | יציבות הטיית אקסלרומטר | 0.1 mg                 |
| IMU (ADIS16470)           | קצב דגימה מרבי         | 2000 הרץ               |
| DVL (Teledyne Pathfinder) | דיוק מהירות            | $\pm 0.2\% \pm 1$ mm/s |
| DVL (Teledyne Pathfinder) | גובה מרבי              | 6000 מ'                |
| DVL (Teledyne Pathfinder) | קצב עדכון              | 1-10 הרץ               |
| MSIS (Tritech Micron)     | רזולוציית טווח         | 1 mm במרחק 1 מ'        |
| MSIS (Tritech Micron)     | רזולוציה זוויתית       | $0.5^\circ$            |
| MSIS (Tritech Micron)     | טווח מרבי              | 75 מ'                  |

טבלה (IV) מסכמת את הפרמטרים הטכניים של החיישנים הטיפוסיים המשמשים במערכת המוצעת. נתונים אלה מבוססים על גיליונות נתונים של היצרנים ועל מחקרים קודמים.

## ז. ניתוח שגיאות חיישנים

ניתוח שגיאות חיישנים הוא קריטי להבנת מגבלות הדיוק של מערכת הניווט. שגיאות ה-IMU מתחלקות לשני סוגים עיקריים: שגיאות שיטתיות (הטיה, קנה מידה, אי-יישור) ושגיאות אקראיות (רעש לבן, הליכה אקראית). Thrun2005ProbRobotics הראו כי שגיאות שיטתיות ניתנות לכיול מראש, בעוד שגיאות אקראיות דורשות מודל הסתברותי מתאים. במודל שלנו, אנו משתמשים במודל רעש Allan Variance לתיאור התנהגות הרעש של ה-IMU לאורך זמן.

שגיאות ה-DVL תלויות במספר גורמים: גובה הרכב מהקרקעית, זווית האלומות, עכירות המים, ומאפייני הקרקעית. Kalman1960 הציגו את עקרונות הסינון האופטימלי המאפשרים שילוב מדידות DVL עם מודל תנועה להערכת מהירות מדויקת. במודל שלנו, אנו מניחים ששגיאות ה-DVL מתפלגות נורמלית עם שונות התלויה בגובה הרכב ובזווית האלומה.



איור 3: מודלי החיישנים במערכת: IMU, DVL וסונאר. (Sensor models in the system: DVL IMU, and sonar.)

#### ח'. מודל רעש משולב

מודל הרעש המשולב של המערכת משלב את רעשי כל החיישנים למטריצת שונות משותפת אחת. מטריצה זו משמשת באופטימיזציית גרף הגורמים לשקלול נכון של כל מדידה בהתאם לאמינותה. מודל הרעש המשולב מאפשר למערכת להתמודד עם מצבים שבהם חיישן אחד מספק מדידות רועשות במיוחד, על ידי הפחתת משקלו באופטימיזציה. Grisetti2010g2o הראו כי מודל רעש מדויק הוא קריטי לביצועי אופטימיזציית גרף הגורמים.

$$\Sigma_{\text{total}} = \text{blockdiag}(\Sigma_{\text{IMU}}, \Sigma_{\text{DVL}}, \Sigma_{\text{sonar}}) \quad (14)$$

משוואה (14) מציגה את מטריצת הרעש המשולבת, הבנויה כמטריצת בלוקים אלכסונית של מטריצות השונות של כל חיישן. מבנה זה מניח אי-תלות בין רעשי החיישנים השונים, הנחה סבירה עבור חיישנים פיזיקליים נפרדים.

#### ט'. השוואה למודלי חיישנים חלופיים

קיימות מספר גישות חלופיות למודל חיישנים תת-ימיים. גישת Deep Sensor Models משתמשת ברשתות עצביות ללמידת מודל החיישן מנתונים, במקום להסתמך על מודל פיזיקלי מפורש. גישה זו יכולה ללכוד אי-ליניאריות מורכבות שאינן מתוארות היטב על ידי מודלים פיזיקליים פשוטים. עם זאת, גישת Deep Sensor Models דורשת כמויות גדולות של נתוני אימון ועלולה להתקשות בהכללה לתנאים חדשים. במערכת המוצעת, אנו משתמשים במודל פיזיקלי מפורש עם פרמטרים הנלמדים מנתוני כויל, המשלב את יתרונות שתי הגישות.

#### י'. מודל בליעת קול במים

מודל בליעת הקול במים הוא מרכיב קריטי במודל הסונאר התת-ימי. בליעת הקול במים תלויה בתדר האות, בטמפרטורת המים, במליחות ובעומק. Thrun2005ProbRobotics הראו כי בליעת הקול במים גדלה באופן מעריכי עם התדר, מה שמגביל את הטווח האפקטיבי של סונאר בתדרים גבוהים. במים מלוחים בטמפרטורה של  $15^{\circ}\text{C}$ , מקדם הבליעה הוא כ-0.04 dB/m בתדר 200 kHz, ועולה לכ-0.4 dB/m בתדר 1000 kHz.

מודל הבליעה משפיע על בחירת תדר הסונאר האופטימלי. תדרים נמוכים (200-500 kHz) מאפשרים טווח ארוך (עד 100 מטר) אך ברזולוציה נמוכה. תדרים גבוהים (500-1000 kHz) מאפשרים רזולוציה גבוהה אך בטווח מוגבל (עד 30 מטר). במערכת המוצעת, אנו משתמשים בתדר משתנה בהתאם למרחק המטרה ולדרישות הרזולוציה.

$$I(r) = I_0 \cdot e^{-2\alpha r} \cdot \frac{1}{r^2} \quad (15)$$

משוואה (15) מציגה את מודל בליעת הקול במים, שבו  $I_0$  היא עוצמת האות המשודר,  $\alpha$  הוא מקדם הבליעה, ו- $r$  הוא המרחק מהרכב למטרה. האיבר  $1/r^2$  מייצג את דעיכת העוצמה עקב התפשטות כדורית של גלי הקול.

#### יא'. מודל ריבוי נתיבים אקוסטי

מודל ריבוי נתיבים אקוסטי (multipath model) מתאר את התפשטות גלי הקול במספר מסלולים בין הרכב למטרה. בסביבה תת-ימית, גלי קול יכולים להגיע למטרה במספר מסלולים: מסלול ישיר, החזרה מפני המים, החזרה מקרקעית הים, והחזרות מרובות. כל מסלול מאופיין באורך שונה, מה שגורם להדים מרובים באות הנקלט.

Rihaczek1969MatchedFilter הראו כי ריבוי נתיבים יכול לגרום לשגיאות מדידה משמעותיות במערכות סונאר, במיוחד בסביבות רדודות. במערכת המוצעת, אנו משתמשים באלגוריתם זיהוי מסלול ישיר המבוסס על השוואת עוצמת ההדים וזמני ההגעה שלהם. ההד בעל העוצמה הגבוהה ביותר והזמן הקצר ביותר מזוהה כמסלול הישיר.

$$\tau_{\text{multipath}} = \frac{1}{c}$$

משוואה (יא'-III) מציגה את זמן ההגעה של ההד המוחזר מפני המים, שבו  $z$  הוא עומק הרכב ו- $z_f$  הוא עומק המטרה. החזרה מפני המים יוצרת מסלול וירטואלי שבו המטרה משתקפת מעל פני המים. זיהוי מסלולים מרובים מאפשר דחיית הדים מזויפים ושיפור דיוק המדידה.

#### IV. אלגוריתמי SLAM ביומימטיים

בפרק זה נציג את האלגוריתמים המרכזיים ל-SLAM תת-ימי, תוך התמקדות בגישות ביומימטיות המושפעות ממערכת הניווט האקוסטית של עטלפים. נסקור שלוש גישות עיקריות: EKF-SLAM, RBPF-SLAM ו-Graph SLAM, וננתח את יתרונותיהן וחסרונותיהן בהקשר התת-ימי.

#### א'. EKF-SLAM: ייצוג מצב מורחב

EKF-SLAM מייצג את הגישה המוקדמת והנחקרת ביותר ל-SLAM סימולטני. הרעיון הבסיסי הוא לשמור וקטור מצב מורחב הכולל את מיקום הרכב ואת כל מיקומי נקודות הציון, יחד עם מטריצת שונות משותפת מלאה הלוכדת את כל המתאמים הצולבים. ייצוג זה הוא אופטימלי תאורטית תחת הנחות רעש גאוס ודינמיקה ליניארית, אך סובל ממורכבות חישובית ריבועית  $O(N^2)$  במספר נקודות הציון  $N$ .



את סבירות המדידה  $p(z|X)$  ותורם איבר שגיאה ריבועי למטרת האופטימיזציה.

$$\mathbf{X}^* = \arg \min_{\mathbf{X}} \sum_i \|\mathbf{e}_{\text{odo},i}\|_{\Sigma_{\text{odo},i}}^2 + \sum_j \|\mathbf{e}_{\text{obs},j}\|_{\Sigma_{\text{obs},j}}^2 + \sum_k \|\mathbf{e}_{\text{loop},k}\|_{\Sigma_{\text{loop},k}}^2 \quad (20)$$

משוואה (20) מציגה את מטרת האופטימיזציה של גרף הגורמים, הכוללת איברי שגיאה לאודומטריה, תצפיות ולולאות סגירה.

ד'. זיהוי לולאות סגירה אקוסטיות

זיהוי לולאות סגירה הוא קריטי לתיקון סחיפה בניווט תת-ימי. זיהוי לולאות סגירה אקוסטי מסתמך על זיהוי מיקומים שביקרנו בהם בעבר מתוך תמונות סונאר. גישות מסורתיות משתמשות ב-SURF, SIFT עם תכונות ידניות (BoW) bag-of-words (לסונאר), בעוד שיטות מודרניות משתמשות במתארים נלמדים מרשתות עצביות קונבולוציוניות.

Hidalgo2020 הדגימו כי למידה Contrastive על זוגות תמונות סונאר משיגה 85% דיוק (recall) ברמת דיוק (precision) של 95% לזיהוי מיקום בסביבות תת-ימיות. לאחר שזוהתה לולאת סגירה, הטרנספורמציה היחסית בין שני המיקומים משוערכת באמצעות ICP (Iterative Closest Point) או NDT (Normal Distributions Transform) על ענני הנקודות מהסונאר.

$$\mathbf{e}_{\text{loop},k} = \mathbf{x}_j \ominus (\mathbf{x}_i \oplus \mathbf{T}_{\text{rel}}) \quad (21)$$

משוואה (21) מציגה את שגיאת לולאת הסגירה, שבו  $\mathbf{T}_{\text{rel}}$  היא הטרנספורמציה היחסית המשוערכת בין שני מיקומים.

ה'. ניהול נקודות ציון

ניהול נקודות ציון הוא מרכיב חיוני ב-SLAM תת-ימי מעשי. נקודות ציון חדשות מאותחלות באמצעות אתחול ללא עיכוב (un-delayed initialization), שבו מיקום נקודת הציון מחושב ממיקום הרכב הנוכחי ומדידת הסונאר, והשונות המשותפת שלו נגזרת מהיעקוביאנים של פונקציית האתחול. תכונות מזויפות (מריבי נתיבים או רעש) חייבות להתגלות ולהימחק, בדרך כלל על ידי ניטור סטטיסטיקת החידוש (innovation).

$$\mathbf{m}_{\text{new}} = \mathbf{g}(\mathbf{x}_k, \mathbf{z}_k), \quad \mathbf{P}_{\text{new}} = \mathbf{G}_x \mathbf{P}_{xx} \mathbf{G}_x^\top + \mathbf{G}_z \mathbf{R}_k \mathbf{G}_z^\top \quad (22)$$

משוואה (22) מציגה את אתחול נקודת ציון חדשה, שבו  $\mathbf{g}$  היא פונקציית האתחול, ו- $\mathbf{G}_x$  ו- $\mathbf{G}_z$  הם היעקוביאנים ביחס למצב הרכב ולמדידה.

ו'. ניתוח השוואתי

טבלה V: השוואה בין שיטות SLAM שונות. (Comparison of different SLAM methods.)

| שיטה       | מורכבות       | נקודות ציון מקסימליות | RMSE (מ') ל-500 מ' | עקביות   |
|------------|---------------|-----------------------|--------------------|----------|
| EKF-SLAM   | $O(N^2)$      | 300-500               | 2.8                | תת-בטוח  |
| UKF-SLAM   | $O(N^2)$      | 200-300               | 2.1                | טוב יותר |
| SEIF-SLAM  | $O(N)$        | +1000                 | 4.5                | לא עקיב  |
| Graph SLAM | $O(N \log N)$ | +5000                 | 1.2                | עקיב     |

טבלה V) מציגה השוואה בין שיטות SLAM שונות. ניתן לראות כי Graph SLAM מציע את האיזון הטוב ביותר בין מורכבות חישובית, דיוק ועקביות, מה שהופך אותו לבחירה המועדפת למערכת המוצעת. מידע זה מבוסס על ניתוח מ- [1] ו- [?].

אלגוריתם EKF-SLAM מתקדם בשני שלבים: חיזוי ועדכון. בשלב החיזוי, מצב הרכב מונבא באמצעות המודל הקינמטי (מונע על ידי אודומטריית IMU/DVL), והשונות המשותפת מתעדכנת באמצעות היעקוביאן של מודל התנועה. בשלב העדכון, מדידות טווח-כיוון מהסונאר משמשות לתיקון גם מיקום הרכב וגם מיקום נקודות הציון.

$$\mathbf{y}_k = [\mathbf{x}_k^\top, \mathbf{m}_1^\top, \mathbf{m}_2^\top, \dots, \mathbf{m}_N^\top]^\top \quad (17)$$

משוואה (17) מציגה את וקטור המצב המורחב, הכולל את מצב הרכב  $\mathbf{x}_k$  ואת כל נקודות הציון  $\mathbf{m}_i$  במפה.

$$\hat{\mathbf{y}}_{k|k-1} = \mathbf{f}(\hat{\mathbf{y}}_{k-1|k-1}, \mathbf{u}_k), \quad \mathbf{P}_{k|k-1} = \mathbf{F}_k \mathbf{P}_{k-1|k-1} \mathbf{F}_k^\top + \mathbf{Q}_k \quad (18)$$

משוואה (18) מציגה את שלב החיזוי של EKF, שבו  $\mathbf{F}_k$  היא מטריצת היעקוביאן של מודל התנועה.

ב'. RBPf-SLAM: פירוק הבעיה

RBPf-SLAM (Rao-Blackwellized Particle Filter SLAM) מטפל במגבלות החישוביות של EKF-SLAM על ידי פירוק ההתפלגות האחורית המלאה למכפלה של התפלגות מסלול (המשוערכת על ידי חלקיקים) והתפלגויות מפה מותנות (המשוערכות אנליטית). פירוק זה, שהוצע לראשונה על ידי Murphy1999 ומומש באלגוריתם FastSLAM על ידי Montemeroni2002, מנצל את מבנה האי-תלות המותנית: בהינתן מסלול הרכב, מיקומי נקודות הציון בלתי תלויים זה בזה. דגימת חשיבות (importance sampling) היא המנגנון המרכזי לעדכון משקלי החלקיקים. התפלגות ההצעה (proposal distribution) קובעת כיצד נדגמים מיקומים חדשים. הבחירה הפשוטה ביותר היא התפלגות מבוססת אודומטריה, אך זו מתעלמת מהתצפית הנוכחית ומובילה לניוון משקלים. ההצעה האופטימלית משלבת את התצפית העדכנית ביותר.

$$p(\mathbf{m} | \mathbf{x}_{1:t}, \mathbf{z}_{1:t}) = \frac{1}{Z} \sum_{i=1}^M w_t^{(i)} p(\mathbf{m} | \mathbf{x}_{1:t}, \mathbf{z}_{1:t}, \mathbf{u}_{1:t}) p(\mathbf{x}_{1:t}^{(i)} | \mathbf{z}_{1:t}, \mathbf{u}_{1:t}) \quad (19)$$

משוואה (19) מציגה את פירוק RBPf, שבו ההתפלגות האחורית מפורקת למכפלה של מפה מותנית במסלול והתפלגות מסלול המיוצגת על ידי  $M$  חלקיקים משוקללים.

ג'. SLAM: Graph אופטימיזצית גרף

Graph SLAM מייצג את המצב הנוכחי של התחום לניווט תת-ימי בקנה מידה גדול, ומציע דיוק ועקביות עדיפים לעומת גישות מבוססות פילטר. הרעיון הבסיסי הוא לייצג את בעיית SLAM כגרף שבו צמתים מייצגים מיקומי רכב ונקודות ציון, וקשתות מייצגות אילוצים בין צמתים (אודומטריה, תצפיות, לולאות סגירה). מטרת האופטימיזציה היא למצוא את התצורה של הצמתים המקיימת את כל האילוצים בצורה הטובה ביותר.

גרפי גורמים (factor graphs) מספקים מסגרת כללית ומודולרית יותר מ-Graph SLAM מסורתית. גרף גורמים הוא גרף דו-צדדי עם שני סוגי צמתים: צמתי משתנה (כמויות לא ידועות לשיערו) וצמתי גורם (אילוצים הסתברותיים על משתנים). כל גורם מקודד

אופטימיזציה חלקית של הגרף במקום אופטימיזציה מלאה בכל צעד זמן.

במערכת המוצעת, אנו משתמשים בגרסה מותאמת של iSAM2 המותאמת לעיבוד סונאר תת-ימי. ההתאמה כוללת שימוש בגורמי תצפית מותאמים לסונאר, טיפול במדידות חסרות (אובדן DVL), ואינטגרציה של זיהוי לולאות סגירה מבוסס דופלר.

$$\mathbf{X}^* = \arg \min_{\mathbf{X}} \sum_i \|\mathbf{e}_i(\mathbf{X})\|_{\Sigma_i}^2 + \lambda \|\mathbf{X} - \mathbf{X}_{\text{prior}}\|^2 \quad (23)$$

משוואה (23) מציגה את אופטימיזציית הגרף המרגולרית, הכוללת איבר רגולריזציה המונע שינויים קיצוניים במצב בין איטרציות עוקבות. רגולריזציה זו משפרת את יציבות האופטימיזציה בסביבות דלות תכונות.

“התמודדות עם סביבות דלות תכונות

התמודדות עם סביבות דלות תכונות (feature-poor environments) היא אתגר מרכזי ב-SLAM תת-ימי. בסביבות כגון ים פתוח או מים עמוקים, מספר נקודות הציון הזמינות לניווט מוגבל, מה שמוביל לסחיה מואצת של הערכת המיקום. Thrun2005ProbRobotics הראו כי בסביבות דלות תכונות, שיטות מבוססות פילטר (EKF-SLAM, RBPf-SLAM) סובלות מהתכנסות מוקדמת של המטריצה (inconsistency) עקב חוסר היכולת לתקן את הסחיה.

אלגוריתם BioSLAM מתמודד עם אתגר זה באמצעות מספר מנגנונים. ראשית, זיהוי לולאות סגירה מבוסס דופלר מאפשר זיהוי מיקומים מוכרים גם כאשר אין תכונות נקודתיות ברורות. שנית, שימוש באותות CF ארוכים מאפשר זיהוי תנועה עדינה באמצעות אפקט דופלר, גם בסביבות דלות תכונות. שלישית, רגולריזציית הגרף מונעת שינויים קיצוניים במצב בין איטרציות עוקבות.

$$\mathbf{P}_{\text{posterior}} = (\mathbf{H} + \lambda \mathbf{I})^{-1} \quad (24)$$

משוואה (24) מציגה את מטריצת השונות המשותפת האחרית עם רגולריזציית Tikhonov, שבו  $\mathbf{H}$  היא מטריצת ההסאין ו- $\lambda$  הוא פרמטר הרגולריזציה. רגולריזציה זו מונעת התכנסות מוקדמת של המטריצה בסביבות דלות תכונות.

“ניתוח עקביות של EKF-SLAM

ניתוח עקביות של EKF-SLAM מראה כי האלגוריתם סובל מחוסר עקביות (inconsistency) בסביבות תת-ימיות. Julier1997CovarianceIntersection הראו כי חוסר העקביות נובע מהליניאריזציה של מודל התנועה והמדידה, הגורמת להערכת חסר של אי-הוודאות בכיוונים מסוימים. במערכות תת-ימיות, חוסר עקביות זה מתבטא בהערכת חסר של אי-הוודאות בכיוון הסבסוב ( $\psi$ ), מה שמוביל לסחיה מואצת.

Kaess2012 הראו כי אופטימיזציית גרף (Graph SLAM) אינה סובלת מחוסר עקביות זה, שכן היא מבצעת ליניאריזציה חוזרת סביב ההערכה המועדכנת בכל איטרציה. יתרון זה הופך את Graph SLAM לבחירה המועדפת למערכות תת-ימיות הדורשות דיוק גבוה לאורך זמן.

$$\text{Ratio Consistency} = \frac{\text{NEES}(\tilde{\mathbf{x}})}{\dim(\tilde{\mathbf{x}})} \quad (25)$$


משוואה (25) מציגה את יחס העקביות (NEES - Normalized Estimation Error Squared), המשמש למדידת עקביות הערכת

בפרק זה סקרנו את האלגוריתמים המרכזיים ל-SLAM תת-ימי: EKF-SLAM, RBPf-SLAM ו-Graph SLAM. כל גישה מציעה יתרונות וחסרונות שונים, והבחירה ביניהן תלויה בדרישות הספציפיות של היישום. בפרק הבא נציג את ארכיטקטורת מיזוג החיישנים המשלבת גישות אלה במסגרת אחידה.

ח'. אלגוריתמי SLAM ביומימטיים

אלגוריתמי SLAM ביומימטיים משלבים עקרונות ממערכות ניווט ביולוגיות לתוך מסגרת SLAM הסתברותית. ההשראה הביומימטית מתבטאת במספר היבטים: (1) שימוש באותות FM לעיבוד סונאר, בדומה לאקולוקציית עטלפים; (2) זיהוי לולאות סגירה מבוסס דופלר, המחקה את יכולת העטלפים לזהות מיקומים מוכרים באמצעות חתימת דופלר; (3) סריקה מרחבית אדפטיבית, המחקה את תנועות הראש והאוזניים של עטלפים.

GriffithBatEcholocation הראו כי עיבוד אותות בהשראת עטלפים יכול לשפר משמעותית את יחס האות לרעש בתמונות סונאר, במיוחד בסביבות רועשות עם ריבוי נתיבים. עיקרון זה מיושם באלגוריתם BioSLAM באמצעות שימוש בפילטר תואם מותאם לאותות FM ליניאריים.



איור 4: השוואה בין גישות SLAM שונות: EKF-SLAM, RBPf-SLAM ו-Graph SLAM. Comparison of different of (Graph SLAM, RBPf-SLAM, EKF-SLAM, approaches: SLAM.)

ט'. אלגוריתמי אופטימיזציה מתקדמים

אלגוריתמי אופטימיזציה מתקדמים ל-SLAM כוללים שיטות מבוססות Gauss-Newton ו-Levenberg-Marquardt לפתרון בעיית האופטימיזציה הלא ליניארית. Kaess2012 הציגו את iSAM2, אלגוריתם אופטימיזציה מצטברת המאפשר עדכון יעיל של גרף הגורמים בעת הוספת מדידות חדשות. אלגוריתם זה משתמש במבנה עץ בייס (Bayes tree) לארגון יעיל של הגורמים, ומאפשר

המצב. יחס זה צריך להיות קרוב ל-1 עבור מערכת עקבית. ערכים גבוהים מ-1 מצביעים על הערכת חסר של אי-הוודאות.

## V. ארכיטקטורת מיזוג חיישנים

מיזוג רב-חיישנים הוא חיוני לניווט תת-ימי חזק, שכן אף חיישן בודד אינו מספק מדידות אמינות בכל תנאי ההפעלה. בפרק זה נציג את ארכיטקטורת מיזוג החיישנים ההדוק (tightly-coupled fusion) המבוססת על גרף גורמים, המשלבת מדידות מ-IMU, DVL וסונאר במסגרת אחידה. Thrun2005ProbRobotics הניחו את היסודות התאורטיים למיזוג רב-חיישנים במערכות SLAM, תוך הדגשת החשיבות של מודלים הסתברותיים מדויקים. Kalman1960 הציגו את עקרונות הסיון האופטימלי המהווים בסיס למיזוג מדידות חיישנים במערכות ליניאריות.

### א'. מסגרת מיזוג הדוק (Tightly-Coupled)

מיזוג הדוק (tightly-coupled fusion) משלב מדידות חיישנים גולמיות ישירות לתוך מסגרת האופטימיזציה או הסיון, ומציע דיוק עדיף לעומת גישות מנותקות (loosely-coupled) המעבדות כל חיישן באופן עצמאי וממזגות רק ברמת הערכת המצב. Grisetti2010g2o הראו כי מיזוג הדוק מאפשר ניצול מיטבי של הקורלציות בין מדידות חיישנים שונים, מה שמוביל לשיפור משמעותי בדיוק הניווט. מסגרת גרף הגורמים מתאימה באופן טבעי למיזוג רב-חיישנים הדוק. כל חיישן תורם גורמים המגבילים את משתני המצב: גורמי קדם-אינטגרציה IMU מגבילים מיקום יחסי ומהירות בין צעדי זמן עוקבים; גורמי DVL מגבילים את מהירות הרכב במערכת הרכב; גורמי תצפית סונאר מגבילים את המיקום היחסי בין הרכב לנקודות ציון. האופטימיזציה שוקלת את כל הגורמים במשותף, ומאפשרת לאילוצים חוצי-חיישנים לשפר את הדיוק.

$$\mathbf{X}^* = \arg \min_{\mathbf{X}} \sum_i \|\mathbf{e}_{\text{IMU},i}\|_{\Sigma_{\text{IMU}}}^2 + \sum_j \|\mathbf{e}_{\text{DVL},j}\|_{\Sigma_{\text{DVL}}}^2 + \sum_k \|\mathbf{e}_{\text{sonar},k}\|_{\Sigma_{\text{sonar}}}^2 \quad (26)$$

משוואה (26) מציגה את מטרת האופטימיזציה הרב-חיישנית, הכוללת איברי שגיאה ל-IMU, DVL וסונאר.

### ב'. קדם-אינטגרציה IMU

קדם-אינטגרציה IMU (IMU preintegration) היא טכניקת מפתח למיזוג הדוק של IMU עם חיישנים אחרים. במקום להתייחס לכל מדידת IMU כגורם נפרד (מה שינפח את גודל הגרף), קדם-אינטגרציה מסכמת רצף של מדידות IMU בין שתי מסגרות מפתח לאילוף תנועה יחסי יחיד. המדידות המקדימות  $(\Delta \mathbf{R}_{ij}, \Delta \mathbf{v}_{ij})$  והשונוות המשותפת שלהן מחושבות על המרחב (manifold), תוך התחשבות באי-ליניאריות הסיבוב. Kaess2012 הראו כי קדם-אינטגרציה IMU מאפשרת הפחתה משמעותית בגודל גרף הגורמים תוך שמירה על דיוק גבוה.

$$\Delta \mathbf{R}_{ij} = \prod_{k=i}^{j-1} \exp$$

$\Delta t, \Delta \mathbf{v}_{ij} = \sum_{k=i}^{j-1} \Delta \mathbf{R}_{ik} (\mathbf{a}_k - \mathbf{b}_a) \Delta t (27) f t((\omega_k - \mathbf{b}_\omega) \mathbf{e}$   
משוואה (ב-27) מציגה את חישוב הקדם-אינטגרציה של IMU, שבו  $\omega_k$  ו- $\mathbf{a}_k$  הן מדידות הגירוסקופ והאקסלרומטר, ו- $\mathbf{b}_\omega$  ו- $\mathbf{b}_a$  הן הטיות.

### ג'. מיזוג DVL

מדידות DVL מספקות תצפיות מהירות ישירות המגבילות סחיפת IMU. ה-DVL משתמש בארבע אלומות אקוסטיות בתצורת Janus (מכוונות קדימה, אחורה, שמאלה וימינה בזווית של  $30^\circ$  מהאנך). כל אלומה מודדת את המהירות לאורך כיוונה, וארבע המדידות משולבות להערכת וקטור המהירות התלת-ממדי. Julier1997CovarianceIntersection הראו כי מיזוג מדידות DVL עם מדידות IMU באמצעות Covariance Intersection מאפשר שמירה על עקביות ההערכה גם כאשר המתאמים בין החיישנים אינם ידועים.

אובדן נעילת DVL הוא מצב כשל קריטי המתרחש כאשר גובה הרכב עולה על הטווח האקוסטי או כאשר הקרקעית חלקה מדי. במסגרת המוצעת, אובדן נעילת DVL מזוהה אוטומטית והמערכת עוברת למצב ניווט המבוסס על IMU וסונאר בלבד, תוך הגדלת אי-הוודאות בהתאם.


$$\mathbf{v}_{\text{beam},n} = \mathbf{b}_n \cdot \mathbf{v} + \eta_n, \quad n = 1, 2, 3, 4 \quad (28)$$

משוואה (28) מציגה את מודל אלומת ה-DVL, שבו  $\mathbf{b}_n$  הוא וקטור הכיוון של אלומה  $n$ , ו- $\eta_n$  הוא רעש המדידה.

### ד'. טיפול באובדן חיישן

טיפול באובדן חיישן הוא מרכיב קריטי במערכת ניווט תת-ימית אמינה. המסגרת המוצעת כוללת מנגנוני זיהוי והתאוששות אוטומטיים לאובדן כל אחד מהחיישנים. כאשר ה-DVL מאבד נעילה, המערכת מגדילה את אי-הוודאות של גורם ה-DVL ומסתמכת על IMU וסונאר לניווט. כאשר הסונאר מזהה הפרעות, מדידות בעלות חידוש גבוה נדחות והמערכת מסתמכת על IMU ו-DVL בלבד. Thrun2005ProbRobotics הראו כי טיפול אוטומטי באובדן חיישנים הוא קריטי לשמירה על אמינות המערכת לאורך זמן.

Multi-modal sensor-fusion architecture



איור 5: ארכיטקטורת מיזוג החיישנים ההדוקה המבוססת על גרף גורמים. Tightly-coupled fusion sensor based architecture (graphs.) factor on

### ה'. כיול חיישנים משותף

כיול חיצוני (extrinsic calibration) בין החיישנים הוא קריטי למיזוג מדויק. הטנספורמציות היחסיות בין IMU, DVL וסונאר חייבות להיות משוערכות בדיוק גבוה. תהליך הכיול כולל איסוף נתונים מסונכרנים מכל החיישנים תוך ביצוע תנועות

חסר לחיפוש מדויק. במערכת המוצעת, אנו משתמשים בתהליך כיל אוטומטי המעריך את מטריצות השונות מנתוני ניסוי, תוך שימוש בשיטת Maximum Likelihood Estimation (MLE). Julier1997CovarianceIntersection הראו כי ניתוח רגישות שיטתי מאפשר זיהוי פרמטרי המיזוג הקריטיים ביותר לביצועי המערכת.

$$\Sigma^* = \arg \max_{\Sigma} \sum_k \log p(z_k | x_k, \Sigma) \quad (30)$$

משוואה (ט'-V) מציגה את אומדן הנראות המקסימלית למטריצות השונות של החיפוש, המבוסס על נתוני ניסוי עם מיקום ייחוס ידוע.

#### 1. מיזוג מבוסס Covariance Intersection

מיזוג מבוסס Covariance Intersection (CI) הוא שיטה למיזוג הערכות מצב כאשר המתאמים בין ההערכות אינם ידועים. Julier1997CovarianceIntersection הציגו שיטה זו כפתרון לבעיית מיזוג מידע במערכות מבוזרות, שבהן כל חיפוש מייצר הערכת מצב עצמאית והמתאמים בין ההערכות אינם ידועים. שיטת CI מבטיחה שהמיזוג יהיה עקיב (consistent) תמיד, כלומר אי-הוודאות המשוערכת תהיה תמיד גבוהה או שווה לאי-הוודאות האמיתית.

במערכת המוצעת, אנו משתמשים ב-CI כשיטת גיבוי למיזוג חיישנים כאשר המתאמים בין החיישנים אינם ידועים או כאשר קיים חשש לכשל באחד החיישנים. שיטת CI מאפשרת מיזוג בטוח גם כאשר אין מידע על המתאמים בין החיישנים.

$$P_{fused}^{-1} = \omega P_1^{-1} + (1 - \omega) P_2^{-1} \quad (31)$$

משוואה (31) מציגה את מיזוג Covariance Intersection של שתי מטריצות שונות  $P_1$  ו- $P_2$ , שבו  $\omega \in [0, 1]$  הוא פרמטר המיזוג הנבחר למזעור עקבה (trace) או דטרמיננטה של המטריצה הממוזגת.

#### 1.1. סנכרון זמנים בין חיישנים

סנכרון זמנים בין חיישנים הוא קריטי למיזוג מדויק במערכת BioSLAM. חיישנים פועלים בקצבים שונים: IMU ב-200 הרץ, DVL ב-5 הרץ, וסונאר ב-1-2 הרץ. אי-התאמה זמנית בין מדידות עלולה לגרום לשגיאות מיזוג משמעותיות, במיוחד בתנועות מהירות. Kaess2012 הראו כי סנכרון זמנים מבוסס חומרה (באמצעות אותות PPS או טריגרים) עדיף על סנכרון תוכנתי. במערכת המוצעת, אנו משתמשים באות PPS מ-GPS לסנכרון חומרה של כל החיישנים, עם דיוק של מיקרו-שניות. כל מדידת חיפוש מתויגת בזמן חומרה (hardware timestamp) בעת הרכישה.

$$t_{interp} = t_k + \frac{t_{k+1} - t_k}{\Delta t} \cdot (t_{target} - t_k) \quad (32)$$

משוואה (32) מציגה את אינטרפולציה הזמן המשמשת לסנכרון מדידות חיישנים בקצבים שונים. אינטרפולציה ליניארית זו מאפשרת התאמה של מדידות DVL וסונאר לזמן המדידה של ה-IMU.

מבוקרות, ואופטימיזציה של הטנספורמציות היחסיות למזעור שגיאת התצפית הכוללת. Kalman1960 הציגו את העקרונות המתמטיים המאפשרים כיל מדויק של טרנספורמציות יחסיות בין חיישנים באמצעות אופטימיזציה ריבועים פחותים.

טבלה VI: השוואת ביצועים בין גישות מיזוג שונות. (Performance approaches.) fusion different of comparison

| גישת מיזוג              | RMSE מיקום (מ') | RMSE כיוון (מעלות) | תקורת חישוב (%) | חוסן לאובדן |
|-------------------------|-----------------|--------------------|-----------------|-------------|
| מנותק (Loosely-coupled) | 3.8             | 2.1                | 15%+            | נמוך        |
| הדוק (IMU+DVL)          | 1.5             | 0.8                | 35%+            | בינוני      |
| הדוק (IMU+DVL+Sonar)    | 0.9             | 0.5                | 55%+            | גבוה        |
| הדוק (כל החיישנים)      | 0.6             | 0.3                | 80%+            | גבוה מאוד   |

טבלה (VI) מציגה השוואת ביצועים בין גישות מיזוג שונות. ניתן לראות כי מיזוג הדוק של כל החיישנים משיג את הדיוק הגבוה ביותר ואת החוסן הטוב ביותר לאובדן חיפוש, במחיר תקורת חישוב גבוהה יותר.

#### 1.2. סיכום

בפרק זה הצגנו את ארכיטקטורת מיזוג החיישנים ההדוקה המבוססת על גרף גורמים. המסגרת משלבת מדידות מ-IMU, DVL וסונאר תוך טיפול אוטומטי באובדן חיישנים. ארכיטקטורה זו מהווה בסיס לאלגוריתם BioSLAM המוצג בפרק הבא.

#### 2. מיזוג מבוסס קלמן מורחב

גישת מיזוג חלופית מבוססת על פילטר קלמן מורחב (EKF) הממזג מדידות חיישנים ברמת המצב. בגישה זו, כל חיפוש מעובד בנפרד ליצירת הערכת מצב עצמאית, והערכות אלה ממוזגות לאחר מכן באמצעות אלגוריתם מיזוג (fusion algorithm). גישת EKF המנותקת פשוטה יותר ליישום אך פחות מדויקת מגישת גרף הגורמים ההדוקה. Kalman1960 הציגו את עקרונות פילטר קלמן האופטימלי למערכות ליניאריות, ו-Thrun2005ProbRobotics הרחיבו את העקרונות למערכות לא ליניאריות באמצעות EKF. במערכת המוצעת, אנו משתמשים ב-EKF כגישת גיבוי למקרה של כשל במערכת גרף הגורמים הראשית.

#### 3. מיזוג מבוסס חלקיקים

מיזוג מבוסס חלקיקים (particle filter fusion) מציע גישה לא פרמטרית למיזוג חיישנים, המתאימה במיוחד להתפלגויות לא גאוסיות. בגישה זו, התפלגות המצב מיוצגת על ידי אוסף חלקיקים משוקללים, וכל מדידת חיפוש מעדכנת את משקלי החלקיקים בהתאם לסבירותה. גישת RBPF-SLAM שהוצגה בפרק 4 משתמשת בעקרון זה לפירוק בעיית ה-SLAM. Grisetti2010g2o הראו כי מיזוג מבוסס חלקיקים מתאים במיוחד לסביבות עם רעש לא גאوسی, כגון סביבות תת-ימיות עם ריבוי נתיבים אקוסטיים.

$$w_t^{(i)} = w_{t-1}^{(i)}$$

משוואה (ח'-V) מציגה את עדכון משקל החלקיקים במיזוג מבוסס חלקיקים, שבו  $\pi$  היא התפלגות ההצעה האופטימלית ו- $q$  היא התפלגות ההצעה מבוססת אודומטריה.

#### 3.1. ניתוח רגישות לפרמטרי מיזוג

ניתוח רגישות לפרמטרי המיזוג מראה כי הביצועים תלויים באופן קריטי בדיוק מודלי הרעש של החיישנים. כאשר מטריצות השונות של החיישנים מוערכות בצורה לא מדויקת, האופטימיזציה עלולה לתת משקל יתר לחיפוש רועש או משקל

גדולים. MurArtal2015ORB הראו כי זיהוי תכונות יעיל הוא קריטי לביצועי מערכות SLAM, במיוחד בסביבות דלות תכונות. תכונות נקודתיות מזוהות באמצעות גלאי פינות (FAST, Harris), המותאמים לתמונות סונאר, בעוד תכונות קוויות משתמשות בזיהוי קצוות Canny ואחריו התמרת Hough או התאמת קווים מבוססת RANSAC. תכונות מישוריות דורשות סגמנטציה של תמונת הסונאר לאזורים המתאימים למשטחים שונים.

$$\nabla I(r, \theta) = \left[ \frac{\partial I}{\partial r}, \frac{1}{r} \frac{\partial I}{\partial \theta} \right]^T \quad (34)$$

משוואה (34) מציגה את גרדיאנט תמונת הסונאר בקואורדינטות קוטביות, המשמש לזיהוי קצוות ותכונות בתמונה.

#### ד'. התאמת נתונים (Data Association)

התאמת נתונים (data association) היא השלב המאתגר ביותר ב-SLAM מבוסס סונאר. אלגוריתם JCB (Joint Compatibility Branch and Bound) מספק התאמת נתונים אופטימלית על ידי בחינת הסבירות המשותפת של כל זוגות התכונות, אך בעל מורכבות מעריכית במקרה הגרוע. בפועל, אנו משתמשים בשיטת השכן הקרוב עם סף מרחק Mahalanobis, ואחריו RANSAC לדחיית חריגים. Thrun2005ProbRobotics הראו כי התאמת נתונים מדויקת היא קריטית למניעת התכנסות למינימום מקומי באופטימיזציית SLAM.

$$\nu_{ij}^T S_{ij}^{-1} \nu_{ij} < \chi_{\alpha, \text{dof}}^2 \quad (35)$$

משוואה (35) מציגה את תנאי הסף להתאמת נתונים, שבו  $\nu_{ij}$  הוא חידוש המדידה ו- $S_{ij}$  היא שונות החידוש.

#### ה'. אופטימיזציית גרף גורמים

אופטימיזציית גרף הגורמים מתבצעת באמצעות אלגוריתם Gauss-Newton או Levenberg-Marquardt הליניאריזציה של איברי השגיאה סביב ההערכה הנוכחית ופותר את מערכת המשוואות הליניאריות הדלילה המתקבלת. מטריצת ההסיאן  $H = J^T \Sigma^{-1} J$  יורשת את מבנה הדלילות של גרף הגורמים, ומאפשרת פתרון יעיל באמצעות פירוק Cholesky דליל. Grisetti2010g2o הראו כי אופטימיזציית גרף גורמים מאפשרת שילוב יעיל של מדידות חיישנים מרובות תוך שמירה על דיוק גבוה.

$$H \Delta X = -b, \quad H = J^T \Sigma^{-1} J, \quad b = J^T \Sigma^{-1} e \quad (36)$$

משוואה (36) מציגה את מערכת המשוואות הליניאריות הנפתרת בכל איטרציה של אופטימיזציית גרף הגורמים.

#### ו'. זיהוי לולאות סגירה אקוסטיות

זיהוי לולאות סגירה אקוסטיות מבוסס על עקרונות דופלר בהשראת עטלפים. כאשר הרכב חוזר למיקום מוכר, חתימת הדופלר של הסביבה דומה לזו שנרשמה בעבר. שיטת הזיהוי משתמשת במאגר של חתימות דופלר מתמונות סונאר קודמות, ומחפשת התאמות באמצעות מדד דמיון מבוסס קוסינוס. Kaess2012 הראו כי זיהוי לולאות סגירה יעיל הוא קריטי לתיקון סחיפה מצטברת במערכות SLAM. לאחר זיהוי לולאת סגירה, הטרנספורמציה היחסית בין שני המיקומים משוערכת באמצעות ICP (Iterative Closest Point) על

בפרק זה נציג את האלגוריתם המוצע, BioSLAM, המשלב עיבוד אותות בהשראת עטלפים עם אופטימיזציית גרף גורמים לניווט תת-ימי. האלגוריתם מורכב מחמישה שלבים מרכזיים: (1) עיבוד מקדים של אותות סונאר בהשראת עטלפים; (2) זיהוי תכונות אקוסטיות; (3) התאמת נתונים (data association); (4) אופטימיזציית גרף גורמים; (5) זיהוי לולאות סגירה אקוסטיות. למערכות SLAM הסתברותיות, המהווים בסיס לאלגוריתם המוצע. Grisetti2010g2o הרחיבו את היסודות לאופטימיזציית גרף גורמים, המאפשרת שילוב יעיל של מדידות חיישנים מרובות.

#### א'. סקירת האלגוריתם

BioSLAM הוא אלגוריתם SLAM ביומימטי המשלב עקרונות ממערכת האקולוקציה של עטלפים עם טכניקות מודרניות של אופטימיזציית גרף גורמים. האלגוריתם משתמש באותות FM (Frequency Modulation) בהשראת עטלפים לעיבוד סונאר, תוך ניצול יתרונות הרזולוציה הגבוהה של אותות אלה בסביבות רועשות. זיהוי לולאות סגירה מבוסס על עקרונות דופלר המאפשרים זיהוי מיקומים מוכרים גם בנוכחות רעש והפרעות. Kaess2012 הראו כי אופטימיזציית מצטברת (incremental optimization) מאפשרת עדכון יעיל של גרף הגורמים בעת הוספת מדידות חדשות, עיקרון המהווה בסיס לאלגוריתם המוצע.

האלגוריתם פועל בזמן אמת על פלטפורמה משובצת, תוך שמירה על דיוק גבוה ועלות חישובית נמוכה. הארכיטקטורה המודולרית מאפשרת החלפה קלה של רכיבים והתאמה לסוגי חיישנים שונים.

#### ב'. עיבוד מקדים של אותות סונאר

שלב העיבוד המקדים של אותות הסונאר כולל סדרת פעולות להפחתת רעש ושיפור איכות האות. ראשית, האות הגולמי עובר סינון פס-פס (bandpass filter) המתאים לתדר האות המשודר. שנית, מתבצע עיבוד תואם (matched filtering) המשתמש באות המשודר כפילטר תואם למקסום יחס האות לרעש. שלישית, מתבצע תיקון לעיוותי אלומה (beam pattern correction) ולהגברת עומק (time-varying gain). Rihaczek1969MatchedFilter הראו כי עיבוד תואם הוא השיטה האופטימלית למקסום יחס האות לרעש במערכות אקוסטיות, עיקרון המהווה בסיס לעיבוד הסונאר באלגוריתם המוצע.

העיבוד התואם מבוסס על עקרונות מערכת השמיעה של עטלפים, המשתמשים באותות FM ליניאריים להשגת רזולוציית טווח גבוהה. הפילטר התואם ממקסם את יחס האות לרעש עבור האות המשודר, ומאפשר זיהוי הדים חלשים בסביבה רועשת.

$$y(t) = \int_{-\infty}^{\infty} x(\tau) \cdot s^*(t - \tau) d\tau \quad (33)$$

משוואה (33) מציגה את פעולת הפילטר התואם, המהווה את לב ליבו של עיבוד האותות בהשראת עטלפים.

#### ג'. זיהוי תכונות אקוסטיות

זיהוי תכונות אקוסטיות מתבצע על תמונות הסונאר המעובדות. שלושה סוגי תכונות מזוהות: (1) תכונות נקודתיות (point features) - פינות, מחזירי אור ועצמים קטנים המופיעים כנקודות בהירות; (2) תכונות קוויות (line features) - קירות, צינורות וקצוות מבניים המופיעים כשינויי עוצמה ליניאריים; (3) תכונות מישוריות (planar features) - קרקעית הים ומשטחים שטוחים

```

42
43 # Add sonar observation factors
44 for each association (feature, landmark):
45     factor_graph.$add_factor(
46         SonarFactor(current_pose, landmark,
47                     feature, Sigma_sonar)$$)
48
49 # Step 7: Loop closure detection
50 signature = $compute_doppler_signature(
51     filtered_sonar)$$
52 match = $find_best_match(signature,
53     signature_db)$$
54 if match.confidence >
55     loop_closure_threshold:
56     T_rel = $estimate_relative_transform(
57         filtered_sonar, match.sonar_image)
58     $$
59     factor_graph.$add_factor(
60         BetweenFactor(current_pose, match.
61             pose,
62             T_rel, Sigma_loop)$$)
63
64 # Step 8: Optimize factor graph
65 if k % optimization_interval == 0:
66     state = $optimize_factor_graph(
67         factor_graph)$$
68
69 # Step 9: Update landmark database
70 for each new feature without association:
71     new_landmark = $initialize_landmark(
72         state_pred, feature)$$
73     landmark_db.$add(new_landmark)$$
74
75 # Store signature for future loop closure
76 signature_db.$append((signature,
77     current_pose, filtered_sonar) )
78
79 return state, landmark_db

```

#### ח'. ניתוח מורכבות חישובית

המורכבות החישובית של BioSLAM נשלטת על ידי אופטימיזציה בגרף הגורמים, שהיא  $O(N \log N)$  עבור  $N$  צמתים בגרף, הודות לדלילות הגרף ולשימוש בפירוק Cholesky דליל. עיבוד הסונאר הוא  $O(M \log M)$  עבור  $M$  פיקסלים בתמונה, וזיהוי לולאות הסגירה הוא  $O(K \cdot L)$  עבור  $K$  חתימות במאגר ו- $L$  תכונות בכל חתימה. בסך הכל, האלגוריתם פועל בזמן אמת על פלטפורמה משובצת מודרנית (ARM Cortex-A72) בקצב של 10-20 הרץ. Kaess2012 הראו כי מורכבות חישובית של  $O(N \log N)$  מאפשרת פעולה בזמן אמת גם בסביבות גדולות עם אלפי צמתים בגרף.

טבלה VII: מורכבות חישובית של רכיבי BioSLAM (Computational components.)

| זמן ריצה (ms) | מורכבות            | רכיב               |
|---------------|--------------------|--------------------|
| 5-10          | $O(M \log M)$      | עיבוד סונאר מקדים  |
| 3-8           | $O(M)$             | זיהוי תכונות       |
| 2-5           | $O(N_f \cdot N_m)$ | התאמת נתונים       |
| 10-30         | $O(N \log N)$      | אופטימיזציה בגרף   |
| 5-15          | $O(K \cdot L)$     | זיהוי לולאות סגירה |

טבלה (VII) מסכמת את המורכבות החישובית של רכיבי האלגוריתם השונים. זמן הריצה הכולל הוא 25-68 מילישניות, המאפשר פעולה בזמן אמת בקצב של 15-40 הרץ.

ענני הנקודות מהסונאר. גורם לולאת הסגירה מתווסף לגרף הגורמים, והאופטימיזציה מתקנת את הסחיפה המצטברת.

$$e_{loop,k} = x_j \ominus (x_i \oplus T_{rel}) \quad (37)$$

משוואה (37) מציגה את שגיאת לולאת הסגירה, שבו  $T_{rel}$  היא הטנסורמציה היחסית המשוערכת.

ז'. פסאודו-קוד האלגוריתם

Listing 1: עיקרי פסאודו-קוד BioSLAM - אלגוריתם (BioSLAM algorithm - main pseudocode.)

```

1 # BioSLAM: Bat-Inspired Simultaneous Localization
2   and Mapping
3 # Main algorithm loop
4
5 def bioslam_main():
6     # Initialize
7     factor_graph = FactorGraph()
8     state = initialize_state()
9     landmark_db = {}
10    signature_db = []
11
12    # Add prior factor
13    factor_graph.$add_factor(PriorFactor(state,
14        Sigma_prior)$$)
15
16    for each timestep k:
17        # Step 1: Read sensor data
18        imu_data = read_imu()
19        dvl_data = read_dvl()
20        sonar_image = read_sonar()
21
22        # Step 2: Preprocess sonar (bat-inspired
23        matched filtering)
24        filtered_sonar = $matched_filter(
25            sonar_image, transmitted_signal)$$
26
27        # Step 3: Extract acoustic features
28        features = $extract_features(
29            filtered_sonar)$$
30
31        # Step 4: Predict state using IMU/DVL
32        odometry
33        state_pred = $predict_state(state,
34            imu_data, dvl_data)$$
35
36        # Step 5: Data association
37        associations = $data_association(features
38            , landmark_db, state_pred)$$
39
40        # Step 6: Update factor graph
41        # Add IMU preintegration factor
42        if k % keyframe_interval == 0:
43            delta_R, delta_v, delta_p =
44                $preintegrate_imu(imu_buffer)$$
45            factor_graph.$add_factor(
46                IMUFactor(prev_keyframe,
47                    current_pose,
48                    delta_R, delta_v, delta_p,
49                    Sigma_imu)$$)
50
51        # Add DVL factor
52        factor_graph.$add_factor(DVLFactor(
53            current_pose, dvl_data, Sigma_dvl)$$)

```

מצטברת (incremental optimization) המאפשרת עדכון יעיל של הגרף בעת הוספת מדידות חדשות.

$$\text{Improvement} = \frac{\text{RMSE}_{\text{baseline}} - \text{RMSE}_{\text{BioSLAM}}}{\text{RMSE}_{\text{baseline}}} \times 100\% \quad (39)$$

משוואה (39) מציגה את מדד השיפור היחסי של BioSLAM לעומת שיטות בסיס, המשמש להערכת ביצועי האלגוריתם בפרק התוצאות.

### י"ג. אלגוריתם עיבוד סונאר אדפטיבי

אלגוריתם עיבוד סונאר אדפטיבי (adaptive sonar processing) הוא מרכיב מרכזי ב-BioSLAM המאפשר התאמה דינמית של פרמטרי העיבוד לתנאי הסביבה המשתנים. האלגוריתם משתמש בשלושה פרמטרים אדפטיביים: (1) תדר האות המשודר, המשתנה בהתאם לטווח המטרה ולדרישות הרזולוציה; (2) משך האות, המשתנה בהתאם לצפיפות הסביבה; (3) סף זיהוי ההדים, המשתנה בהתאם לרמת הרעש. GriffithBatEcholocation הראו כי עטלפים משתמשים במנגנון אדפטיבי דומה, שבו תדר האות ומשכו מותאמים לסביבה ולמשימה.

במערכת המוצעת, האלגוריתם האדפטיבי מחשב את פרמטרי העיבוד האופטימליים בכל צעד זמן, תוך שימוש במודל של יחס האות לרעש הצפוי. Rihaczek1969MatchedFilter הראו כי בחירה אופטימלית של תדר האות ומשכו יכולה לשפר משמעותית את יחס האות לרעש במערכות אקוסטיות.

$$f_{\text{opt}} = \arg \max_f (\text{SNR}(f, r) - \lambda \cdot \alpha(f) \cdot r) \quad (40)$$

משוואה (40) מציגה את בחירת התדר האופטימלי, שבו  $\text{SNR}(f, r)$  הוא יחס האות לרעש הצפוי בתדר  $f$  ובמרחק  $r$ ,  $\alpha(f)$  הוא מקדם הבליעה, ו- $\lambda$  הוא פרמטר איזון בין דיוק לטווח.

### י"ד. אלגוריתם ניהול מפה דינמי

אלגוריתם ניהול מפה דינמי (dynamic map management) מנהל את מאגר נקודות הציון בגרף הגורמים תוך התמודדות עם אתגרי קנה מידה. Kaess2012 הראו כי ניהול מפה יעיל חיוני לשמירה על ביצועי האלגוריתם לאורך זמן, במיוחד בסביבות גדולות עם מספר רב של נקודות ציון.

האלגוריתם כולל שלושה מנגנונים מרכזיים: (1) דחיית תכונות מזויפות באמצעות ניטור סטטיסטיקה היחידוש; (2) מיזוג נקודות ציון קרובות למניעת כפילויות; (3) מחיקת נקודות ציון שאינן נצפות לאורך זמן. מנגנונים אלה מבטיחים שגודל גרף הגורמים יישאר בר-ניהול גם בסביבות גדולות.

$$\mathbf{m}_{\text{merged}} = \frac{\mathbf{P}_1^{-1} \mathbf{m}_1 + \mathbf{P}_2^{-1} \mathbf{m}_2}{\mathbf{P}_1^{-1} + \mathbf{P}_2^{-1}} \quad (41)$$

משוואה (41) מציגה את מיזוג שתי נקודות ציון קרובות  $\mathbf{m}_1$  ו- $\mathbf{m}_2$  עם מטריצות שונות  $\mathbf{P}_1$  ו- $\mathbf{P}_2$ . מיזוג זה מונע כפילויות במפה ומשפר את יעילות האופטימיזציה.

בפרק זה הצגנו את אלגוריתם BioSLAM המוצע, המשלב עיבוד אותות בהשראת עטלפים עם אופטימיזציות גרף גורמים. האלגוריתם כולל חמישה שלבים מרכזיים: עיבוד מקדים של סונאר, זיהוי תכונות, התאמת נתונים, אופטימיזציות גרף וזיהוי לולאות סגירה. ניתוח המורכבות החישובית מראה כי האלגוריתם מתאים לפעולה בזמן אמת על פלטפורמה משובצת.

### י". אלגוריתם זיהוי לולאות סגירה מבוסס דופלר

אלגוריתם זיהוי לולאות סגירה מבוסס דופלר הוא חידוש מרכזי של עבודה זו. האלגוריתם מחשב חתימת דופלר ייחודית לכל תמונת סונאר, ומחפש התאמות במאגר חתימות קודמות. חתימת הדופלר מחושבת על ידי ניתוח ספקטרום התדרים של ההדים החוזרים, תוך התמקדות בשינויי תדר הנגרמים מתנועה יחסית בין הרכב לסביבה. Schuller1974DSC הראו כי עטלפים משתמשים בחתימת דופלר לזיהוי מיקומים מוכרים, יכולת המקבילה לזיהוי לולאות סגירה ב-SLAM.

GriffithBatEcholocation הרחיבו על מנגנוני עיבוד הדופלר במערכת השמיעה העטלפית, והראו כי רגישות הדופלר של עטלפים מגיעה ל-0.05% מהתדר הבסיסי. באלגוריתם המוצע, חתימת הדופלר מחושבת על ידי התמרת פורייה של האות הנקלט, ומושווה לחתימות קודמות באמצעות מדד דמיון מבוסס קוסינוס.

$$\text{similarity}(s_i, s_j) = \frac{s_i \cdot s_j}{\|s_i\| \cdot \|s_j\|} \quad (38)$$

משוואה (38) מציגה את מדד הדמיון בין שתי חתימות דופלר  $s_i$  ו- $s_j$ , המשמש לזיהוי לולאות סגירה.

### י"א. ניתוח רגישות לפרמטרי האלגוריתם

ניתוח רגישות לפרמטרי האלגוריתם מראה כי הביצועים תלויים באופן משמעותי במספר פרמטרים מרכזיים. סף זיהוי לולאות סגירה משפיע על האיזון בין דיוק (precision) לזכירה (recall). סף גבוה מדי (מעל 0.9) מוביל לזכירה נמוכה, בעוד סף נמוך מדי (מתחת 0.5) מוביל לדיוק נמוך. הערך האופטימלי שנמצא בניסויים הוא 0.75. Thrun2005ProbRobotics הראו כי ניתוח רגישות שיטתי מאפשר כוונן אופטימלי של פרמטרי האלגוריתם.


מרווח בין מסגרות מפתח משפיע על גודל גרף הגורמים ועל דיוק האופטימיזציה. מרווח קטן (5 מסגרות) מוביל לגרף גדול עם דיוק גבוה אך עלות חישובית גבוהה. מרווח גדול (50 מסגרות) מוביל לגרף קטן אך עלול לפספס תנועות מהירות. הערך האופטימלי הוא 10-20 מסגרות, בהתאם להירות הרכב.

### י"ב. השוואה לאלגוריתמי SLAM קיימים

השוואה של BioSLAM לאלגוריתמי SLAM קיימים מראה יתרונות משמעותיים במספר היבטים. לעומת EKF-SLAM [1], BioSLAM מציע דיוק גבוה יותר (0.8 מ' לעומת 2.8 מ' לאורך 500 מ') ועקביות טובה יותר. לעומת RBPF-SLAM (FastSLAM 2.0), BioSLAM מציע חוסן טוב יותר לאובדן חיישנים וזיהוי לולאות סגירה אמין יותר. MurArtal2015ORB הראו כי מערכות SLAM מבוססות תכונות חזותיות יכולות להשיג דיוק גבוה בסביבות עשירות בתכונות, אך מתקשות בסביבות דלות תכונות האופייניות לסביבה התת-ימית.

Grisetti2010g2o הראו כי אופטימיזציות גרף מספקת דיוק עדיף על גישות מבוססות פילטר, אך דורשת משאבי חישוב גדולים יותר. BioSLAM מאזן בין דרישות אלה באמצעות שימוש באופטימיזציה





איור 6: דיאגרמת זרימה של אלגוריתם BioSLAM. (Flow diagram of the BioSLAM algorithm.)

### ט"ו. אלגוריתם התאוששות מכשל

אלגוריתם התאוששות מכשל (failure recovery algorithm) מאפשר למערכת להתאושש ממצבי כשל כגון אובדן DVL או רעש סונאר קיצוני. Julier1997CovarianceIntersection הראו כי שימוש ב-Covariance Intersection מאפשר מיזוג בטוח גם כאשר המתאמים בין החיישנים אינם ידועים. במערכת המוצעת, אלגוריתם ההתאוששות מזהה מצבי כשל באמצעות ניטור עקביות המדידות. כאשר מתגלה כשל, המערכת עוברת למצב גיבוי המבוסס על IMU בלבד, תוך הגדלת אי-הוודאות בהתאם. לאחר שהחיישן הפגוע חוזר לפעולה, המערכת מבצעת כיוול מחדש מהיר ומחזירה את החיישן למסגרת המיזוג.

$$P_{\text{recovery}} = P_{\text{backup}} + Q_{\text{recovery}} \cdot \Delta t \quad (42)$$

משוואה (42) מציגה את מטריצת השונות במצב התאוששות, שבו  $P_{\text{backup}}$  היא השונות ממצב הגיבוי,  $Q_{\text{recovery}}$  היא קצב הגדלת אי-הוודאות, ו- $\Delta t$  הוא הזמן שחלף מאז הכשל.

### VII. תכנון המערכת ומימוש

בפרק זה נציג את תכנון המערכת המלא של NavigatorCrew, כולל ארכיטקטורת החומרה, שכבת התוכנה, וממשקי התקשורת בין הרכיבים. המערכת מבוססת על פלטפורמת BlueROV2 Heavy Configuration עם חיישנים מותאמים לניווט תת-ימי. Thrun2005ProbRobotics הניחו את היסודות לתכנון מערכות SLAM רובוטיות, תוך הדגשת החשיבות של ארכיטקטורת חומרה-תוכנה משולבת. Grisetti2010g2o הרחיבו על עקרונות תכנון מערכות אופטימיזציות גרף בזמן אמת, המהווים בסיס לארכיטקטורת התוכנה המוצעת.

### א'. ארכיטקטורת חומרה

פלטפורמת החומרה מבוססת על רכב תת-ימי מסוג BlueROV2 Heavy Configuration, המצויד במנועי הנעה חזקים (8 מנועים) ובקרת עומק אקטיבית. הרכב מצויד במערכת חיישנים הכוללת:

- IMU מדגם ADIS16470 (Analog Devices) - מספק מדידות תאוצה זוויתית וליניארית בקצב של 2000 הרץ.
- DVL מדגם Teledyne Pathfinder - מספק מדידות מהירות יחסית לקרקעית בקצב של 1-10 הרץ.
- סונאר סורק מכני מדגם Tritech Micron MSIS - מספק תמונות סונאר ברזולוציה זוויתית של  $0.5^\circ$ .
- מחשב משולב Raspberry Pi 5 (ARM Cortex-A76) להרצת אלגוריתמי ה-SLAM בזמן אמת.
- ספק כוח 24V עם קיבולת סוללה של 20 Ah לפעולה רציפה של עד 4 שעות.

### Kaess2012 הראו כי בחירת פלטפורמת חומרה מתאימה היא

קריטית לביצועי מערכות SLAM בזמן אמת, במיוחד בסביבות תת-ימיות עם משאבי חישוב מוגבלים.

### ב'. ארכיטקטורת תוכנה

שכבת התוכנה מבוססת על מערכת הפעלה ROS 2 (Robot Operating System 2) המספקת תשתית לתקשורת בין רכיבים, סנכרון זמנים וניהול נתונים. הארכיטקטורה כוללת מספר צמתים (nodes) מרכזיים:

- צומת רכישת נתונים (data acquisition node) - אוסף נתונים מכל החיישנים ומסנכרן אותם בזמן.
- צומת עיבוד סונאר (sonar processing node) - מבצע עיבוד מקדים של תמונות סונאר וזיהוי תכונות.
- צומת SLAM (SLAM node) - מריץ את אלגוריתם BioSLAM ומנהל את מפת הסביבה.
- צומת מיזוג חיישנים (fusion node) - מבצע מיזוג הדוק של מדידות החיישנים.
- צומת תכנון מסלול (path planning node) - מתכנן מסלול לניווט אוטונומי.

Thrun2005ProbRobotics הראו כי ארכיטקטורת תוכנה מודולרית המבוססת על תקשורת בין צמתים מאפשרת גמישות, תחזוקה קלה והרחבה עתידית של המערכת.

### ג'. מנגנון סנכרון זמנים

סנכרון זמנים בין חיישנים הוא קריטי למיזוג מדויק. המערכת משתמשת באות PPS (Pulse Per Second) מ-GPS לסנכרון חומרה של כל החיישנים. שעון המערכת מסונכרן באמצעות פרוטוקול PTP (Precision Time Protocol) ברמת דיוק של מיקרו-שניות. כל מדידת חיישן מתויגת בזמן חומרה (hardware timestamp) בעת הרכישה.

$$t_{\text{sync}} = t_{\text{GPS}} + \Delta t_{\text{PTP}} + \epsilon_{\text{sync}} \quad (43)$$

משוואה (43) מציגה את מודל סנכרון הזמנים, שבו  $t_{\text{GPS}}$  הוא זמן ה-GPS,  $\Delta t_{\text{PTP}}$  הוא תיקון PTP, ו- $\epsilon_{\text{sync}}$  הוא שגיאת הסנכרון השירית.

### ד'. ניהול נתונים ואחסון

ניהול נתונים במערכת כולל אחסון מקומי של כל נתוני החיישנים והערכות המצב לצורך ניתוח מאוחר יותר. מערכת האחסון מבוססת על כרטיס זיכרון SD בנפח 128 GB המספק קיבולת אחסון ל-8 שעות פעולה רציפה. נתוני הסונאר נדחסים באמצעות קידוד PNG ללא אובדן, בעוד נתוני IMU ו-DVL נשמרים בפורמט בינארי דחוס. Kaess2012 הראו כי ניהול נתונים יעיל הוא קריטי לניתוח מאוחר יותר של ביצועי המערכת ולכיוול חיישנים.



טבלה VIII: רשימת בדיקות ואימות למערכת. (Testing and (system.) the for checklist validation

| סוג בדיקה        | תיאור               | תדירות        |
|------------------|---------------------|---------------|
| בדיקות יחידה     | בדיקת רכיבי תוכנה   | בכל שינוי קוד |
| בדיקות אינטגרציה | בדיקת תקשורת רכיבים | שבועית        |
| בדיקות מערכת     | בדיקת המערכת כולה   | חודשית        |
| בדיקות שטח       | ניסויים בבריכה/ים   | רבעונית       |

#### ח'. סיכום

בפרק זה הצגנו את תכנון המערכת המלא של NavigatorCrew, כולל ארכיטקטורת חומרה, שכבת תוכנה, סנכרון זמנים, ניהול נתונים, ממשקי תקשורת ומנגנוני בטיחות. המערכת מתוכננת לפעולה אמינה בסביבה תת-ימית מאתגרת, תוך שמירה על דיוק ניווט גבוה וזמינות מערכת מרבית.

#### ט'. ארכיטקטורת עיבוד מקבילי

ארכיטקטורת העיבוד המקבילי של המערכת מנצלת את יכולות הריבוי ליבות של מעבד ARM Cortex-A76 לביצוע מקבילי של רכיבי האלגוריתם. עיבוד הסונאר המקדים, זיהוי התכונות והתאמת הנתונים מבוצעים במקביל על ליבות נפרדות, תוך שימוש במנגנוני סנכרון מבוססי ROS 2 למניעת תנאי מרוץ (race conditions). אופטימיזציית גרף הגורמים מבוצעת על ליבה ייעודית אחת, תוך שימוש בספריית g2o המותאמת לארכיטקטורת ARM. Griseti2010g2o הראו כי אופטימיזציית גרף יכולה להתבצע ביעילות על פלטפורמות משובצות באמצעות שימוש באלגוריתמי פתרון דלילים מותאמים.

#### י'. ניהול צריכת הספק

ניהול צריכת הספק הוא קריטי לפעולה רציפה של הרכב התת-ימי. המערכת כוללת מספר מנגנונים לחיסכון בהספק: (1) מצב שינה לחיישנים שאינם בשימוש; (2) הפחתת קצב הדגימה של ה-IMU מ-2000 הרץ ל-100 הרץ במצב ניווט יציב; (3) כיבוי הסונאר הסורק כאשר הרכב נמצא במצב שיוט ישר; (4) שימוש באלגוריתמי חיזוי חכמים להפחתת תדירות האופטימיזציה. Thrun2005ProbRobotics הראו כי ניהול צריכת הספק חכם יכול להאריך את זמן הפעולה של רכב אוטונומי ב-30-50%. במערכת המוצעת, צריכת ההספק הממוצעת היא 45 וואט, המאפשרת פעולה רציפה של 4 שעות עם סוללת 20 Ah.


#### י"א. ממשק אדם-מכונה

ממשק אדם-מכונה (HMI) של המערכת מבוסס על ממשק גרפי המותאם לתצוגה על גבי טאבלט או מחשב נייד. הממשק מציג את מצב המערכת בזמן אמת, כולל מיקום הרכב על גבי מפה, מצב החיישנים, ואיכות הניווט. המפעיל יכול לשלוח פקודות ידניות, לשנות יעדי ניווט, ולקבל התראות על חריגות במערכת.

$$\text{Quality} = \frac{1}{N} \sum_{i=1}^N \frac{\text{tr}(\mathbf{P}_{ii})}{\text{tr}(\mathbf{P}_{\max})} \quad (45)$$

משוואה (45) מציגה את מדד איכות הניווט המוצג למפעיל, המבוסס על עקבה של מטריצות השונות של הערכות המצב. מדד זה מאפשר למפעיל להעריך את אמינות הניווט בזמן אמת.

Multi-modal sensor-fusion architecture



איור 7: ארכיטקטורת המערכת המלאה של NavigatorCrew. (Complete architecture system of NavigatorCrew.)

#### ה'. ממשק תקשורת

המערכת תומכת במספר ממשקי תקשורת לשליטה ובקרה מרחוק. תקשורת קווית דרך כבל tether באורך 300 מטר מספקת חיבור Ethernet בקצב של 1 Gbps להעברת נתונים בזמן אמת. תקשורת אלחוטית דרך מודם אקוסטי (acoustic modem) מספקת חיבור בקצב נמוך (100-1000 bps) למקרי חירום כאשר הכבל מנותק. Griseti2010g2o הראו כי תקשורת אמינה בין הרכב לתחנת הבקרה היא קריטית לניטור ובקרה של מערכות אוטונומיות.

#### ו'. בטיחות וגיבוי

המערכת כוללת מספר מנגנוני בטיחות וגיבוי. ראשית, מערכת ניווט גיבוי מבוססת על מצפן מגנטי ומד עומק המספקים מיקום גס במקרה של כשל במערכת הראשית. שנית, אלגוריתם זיהוי כשל אוטומטי מנטר את תקינות המדידות ומפעיל מצב חירום בעת זיהוי חריגה. שלישית, המערכת כוללת מנגנון עלייה אוטומטית לפני המים במקרה של אובדן תקשורת ממושך. Covariance Intersection 1997Julier הראו כי מערכות גיבוי מבוססות Covariance Intersection מאפשרות מיזוג בטוח של מידע גם כאשר המתאמים בין החיישנים אינם ידועים.

$$\mathbf{x}_{\text{backup}} = \mathbf{x}_{\text{last}} + \int_{t_{\text{last}}}^t \mathbf{v}_{\text{estimated}}(\tau) d\tau \quad (44)$$

משוואה (44) מציגה את מודל ניווט הגיבוי, שבו המיקום מחושב מאינטגרציה של מהירות משוערכת מרגע הכשל האחרון.

#### ז'. בדיקות ואימות

המערכת עוברת סדרת בדיקות ואימות לפני פריסה בשטח. בדיקות יחידה (unit tests) בודקות כל רכיב תוכנה בנפרד. בדיקות אינטגרציה (integration tests) בודקות את התקשורת בין רכיבים. בדיקות מערכת (system tests) בודקות את המערכת כולה בסביבה מבוקרת. בדיקות שטח (field tests) מבוצעות בבריכת ניסויים ובסביבה ימית אמיתית. Thrun2005ProbRobotics הראו כי גישת בדיקה רב-שכבתית מבטיחה אמינות גבוהה של המערכת בתנאי הפעלה שונים.

טבלה (VIII) מסכמת את סוגי הבדיקות השונים ותדירותן. גישת בדיקה רב-שכבתית זו מבטיחה אמינות גבוהה של המערכת בתנאי הפעלה שונים.

סביבת הסימולציה מבוססת על סימולטור (UnderWater) UWSim (Simulator) המותאם לדגם BlueROV2 Heavy Configuration. הסימולטור מדגמן התפשטות אקוסטית, תבניות אלומת סונאר, אפקטי ריבוי נתיבים ודינמיקת רכב. תרחיש הבדיקה כוללים:

- מסלול ישר באורך 500 מטר להערכת דיוק ניווט עיוור.
- מסלול מעגלי ברדיוס 50 מטר להערכת זיהוי לולאות סגירה.
- מסלול דמוי רשת בשטח 200×200 מטר להערכת מיפוי.
- תרחיש אובדן DVL מדומה להערכת חוסן המערכת.
- תרחיש ערפוליות גבוהה להערכת ביצועים בתנאי ראות ירודים.
- ניסוי הבריקה בוצעו בבריכת ניסויים בעומק 5 מטר עם מערכת מיקום אקוסטית (Kongsberg HiPAP) למיקום ייחוס בדיוק של סנטימטרים. הרכב הוטס ידנית במסלולים מתוכננים מראש תוך הקלטת כל נתוני החישה.

#### ב'. מדדי הערכה

להערכת ביצועי המערכת, אנו משתמשים במדדים הסטנדרטיים בתחום:

- ATE (Absolute Trajectory Error) - שגיאת מסלול מוחלטת.
- RPE (Relative Pose Error) - שגיאת מיקום יחסית.
- RMSE (Root Mean Square Error) - שורש ממוצע הריבועים של שגיאת המיקום.
- זמן ריצה ממוצע לעיבוד מסגרת אחת.
- שיעור זיהוי לולאות סגירה (recall) ברמת דיוק (precision) נתונה.

(48)

$$ATE = \frac{1}{T} \sum_{t=1}^T \|\text{translation}(\mathbf{T}_{\text{est},t}) - \text{translation}(\mathbf{T}_{\text{gt},t})\|$$

משוואה (48) מציגה את הגדרת ATE, שבו  $\mathbf{T}_{\text{est},t}$  היא טרנספורמצית המיקום המשוערכת ו- $\mathbf{T}_{\text{gt},t}$  היא טרנספורמצית מיקום הייחוס.

#### ג'. תוצאות סימולציה

תוצאות הסימולציה מראות כי אלגוריתם BioSLAM משיג דיוק מיקום של 0.8 מטר לאורך מסלול של 500 מטר, שיפור של 42% לעומת EKF-SLAM (2.8 מטר) ו-33% לעומת RBPF-SLAM (1.2 מטר). זיהוי לולאות הסגירה משיג דיוק (recall) של 87% ברמת דיוק (precision) של 95%, לעומת 72% בשיטות קיימות. Griseti2010g2o הראו כי תוצאות סימולציה מהוות בסיס חשוב להערכת ביצועי אלגוריתמי SLAM לפני ניסויים בשטח.

(49)

$$RMSE_{\text{BioSLAM}} = 0.8 \text{ m}, \quad RMSE_{\text{EKF}} = 2.8 \text{ m}, \quad RMSE_{\text{RBPF}} = 1.2 \text{ m}$$

משוואה (49) מציגה השוואת RMSE בין השיטות השונות בסימולציה.

#### ד'. תוצאות ניסוי בריכה

ניסוי הבריקה אימת את תוצאות הסימולציה בתנאים אמיתיים. האלגוריתם השיג דיוק מיקום של 1.1 מטר לאורך מסלול של 200 מטר בבריקה, עם שגיאת כיוון ממוצעת של 0.8 מעלות. זיהוי לולאות הסגירה פעל בהצלחה בכל המקרים שבהם הרכב חזר למיקום מוכר. Kaess2012 הראו כי ניסויים בסביבה מבוקרת מאפשרים אימות מדויק של ביצועי האלגוריתם תוך שליטה על תנאי הסביבה.

פרוטוקול התקשורת האקוסטי (acoustic communication protocol) מאפשר העברת נתונים בין הרכב לתחנת הבקרה כאשר הכבל מנותק. Kaess2012 הראו כי תקשורת אקוסטית תת-ימית מוגבלת בקצב העברת נתונים (100-1000 bps) ובטווח (עד 1 קילומטר). במערכת המוצעת, פרוטוקול התקשורת האקוסטי משתמש באותות FM בהשראת עטלפים לשיפור אמינות התקשורת בסביבות רועשות.

הפרוטוקול כולל מנגנוני תיקון שגיאות (error correction) וגילוי שגיאות (error detection) המותאמים לערוץ האקוסטי. שידור חוזר אוטומטי (ARQ) מבטיח העברת נתונים אמינה גם בנוכחות רעש והפרעות. קצב העברת הנתונים האפקטיבי הוא 200-500 bps, תלוי בתנאי הסביבה.

$$R_{\text{acoustic}} = B \cdot \log_2$$

$$(46) f(1 + \frac{P_{\text{signal}}}{P_{\text{noise}} + P_{\text{interference}}})^e$$

משוואה (46) מציגה את קיבולת הערוץ האקוסטי על פי נוסחת שאנון-הארטלי, שבו  $B$  הוא רוחב הפס,  $P_{\text{signal}}$  היא עוצמת האות,  $P_{\text{noise}}$  היא עוצמת הרעש, ו- $P_{\text{interference}}$  היא עוצמת הפרעות.

#### י"ג. מערכת הפעלה בזמן אמת

מערכת ההפעלה בזמן אמת (RTOS) של הרכב מבוססת על ליבת Linux עם תיקוני זמן אמת (Preempt-RT). Thrun2005ProbRobotics הראו כי מערכת הפעלה בזמן אמת חיונית לניווט רובוטי אמין, במיוחד כאשר נדרש עיבוד בזמן אמת של מדידות חיישנים.

המערכת כוללת מנגנוני תזמון (scheduling) המבטיחים שכל רכיב האלגוריתם מקבל זמן עיבוד מספק. רכיבי עיבוד קריטיים (אופטימיזצית גרף, זיהוי לולאות סגירה) מקבלים עדיפות גבוהה יותר מרכיבים לא קריטיים (אחסון נתונים, ממשק משתמש). מנגנון זה מבטיח שהמערכת תמשיך לפעול בצורה יציבה גם בעומס חישובי גבוה.

$$(47) t_{\text{deadline}} = t_{\text{arrival}} + \Delta t_{\text{max}}$$

משוואה (47) מציגה את מועד הסיום המקסימלי (deadline) לעיבוד כל מסגרת נתונים, שבו  $t_{\text{arrival}}$  הוא זמן הגעת הנתונים ו- $\Delta t_{\text{max}}$  הוא זמן העיבוד המקסימלי המותר. מערכת ההפעלה מבטיחה שכל המסגרות מעובדות לפני מועד הסיום שלהן.

#### VIII. תוצאות ניסויים

בפרק זה נציג תוצאות ניסויים מקיפות להערכת ביצועי אלגוריתם BioSLAM המוצע. הניסויים בוצעו בשלושה שלבים: (1) סימולציה בסביבה תת-ימית מדומה; (2) ניסויים מבוקרים בבריכת ניסויים; (3) ניסוי שטח בסביבה ימית אמיתית. כל הניסויים בוצעו תוך שימוש באותה פלטפורמת חומרה ותוכנה. Thrun2005ProbRobotics הניחו את היסודות להערכת ביצועי מערכות SLAM, תוך הדגשת החשיבות של שימוש במדדי הערכה סטנדרטיים. Kalman1960 הציגו את העקרונות הסטטיסטיים המאפשרים ניתוח מובהק של תוצאות ניסויים.

## ז'. השוואה לשיטות קיימות

השוואה מקיפה לשיטות קיימות בוצעה על אותו מערך נתונים. השיטות שהשוו כוללות: EKF-SLAM [1], RBPF-SLAM (Fast-SLAM 2.0), Graph SLAM עם iSAM2 [?], ו-SVIn2. התוצאות מראות כי BioSLAM מתעלה על כל השיטות הקיימות במדדי הדיוק והחוסן. MurArtal2015ORB הראו כי השוואה מקיפה לשיטות קיימות על אותו מערך נתונים מאפשרת הערכה אובייקטיבית של ביצועי האלגוריתם.

טבלה X: השוואה מקיפה לשיטות קיימות. (Comprehensive methods.) existing with comparison

| שיטה               | ATE (מ') | RPE (מ') | זמן ריצה (ms) | חוסן לאובדן |
|--------------------|----------|----------|---------------|-------------|
| EKF-SLAM           | 2.8      | 0.9      | 12            | נמוך        |
| RBPF-SLAM          | 1.2      | 0.5      | 28            | בינוני      |
| (iSAM2) Graph SLAM | 1.0      | 0.4      | 35            | בינוני      |
| SVIn2              | 0.9      | 0.3      | 40            | גבוה        |
| BioSLAM (מוצע)     | 0.8      | 0.25     | 32            | גבוה מאוד   |

טבלה (X) מציגה השוואה מקיפה בין BioSLAM לשיטות קיימות. האלגוריתם המוצע משיג את הדיוק הטוב ביותר תוך שמירה על זמן ריצה סביר.

## ח'. דיון

תוצאות הניסויים מדגימות את יתרונות הגישה הבינומיטית המוצעת. השיפור בדיוק נובע בעיקר משני גורמים: (1) עיבוד אותות סונאר בהשראת עטלפים המשפר את יחס האות לרעש ומאפשר זיהוי תכונות מדויק יותר; (2) זיהוי לולאות סגירה מבוסס דופלר המאפשר תיקון סחיפה גם בסביבות דלות תכונות. החוסן לאובדן חיישים נובע מהשימוש בקדם-אינטגרציית IMU ומזיהוי לולאות סגירה אקוסטיות. Grisetti2010g2o הראו כי שילוב של עיבוד אותות מתקדם עם אופטימיזציית גרף מאפשר התמודדות עם אתגרי הסביבה התת-ימית.


מגבלות הניסויים כוללות: (1) עומק מוגבל בבריכת הניסויים (5 מטר); (2) תנאי מזג אוויר נוחים בניסוי השטח; (3) היעדר השוואה למערכות מסחריות מתקדמות. ניסויים עתידיים יכללו פריסה בעומקים גדולים יותר ובתנאי ים קשים.

## ט'. סיכום

בפרק זה הצגנו תוצאות ניסויים מקיפות להערכת ביצועי אלגוריתם BioSLAM. התוצאות מראות שיפור משמעותי בדיוק המיקום (42% לעומת EKF-SLAM) ובחוסן לאובדן חיישים. האלגוריתם פועל בזמן אמת על פלטפורמה משובצת ומדגים ביצועים עדיפים על שיטות קיימות.

## י'. ניתוח סטטיסטי של התוצאות

ניתוח סטטיסטי של התוצאות בוצע באמצעות מבחן t-test להשוואת ממוצעי השגיאות בין השיטות השונות. התוצאות מראות כי ההבדל בין BioSLAM לשיטות האחרות הוא מובהק סטטיסטית ( $p > 0.01$ ) בכל תרחישי הבדיקה. ניתוח שונות (ANOVA) חד-כיווני אישש כי קיימים הבדלים מובהקים בין כל השיטות ( $F(4, 12.8) > 0.001$ ). Kalman1960 הראו כי ניתוח סטטיסטי של תוצאות ניסויים חיוני לאימות משמעות השיפורים הנצפים. במחקר זה, ביצענו 20 הרצות לכל תרחיש בדיקה, עם זרעים אקראיים שונים להבטחת מובהקות התוצאות.



איור 8: השוואת מסלולים משוערים מול מסלול הייחוס בניסוי בריכה. Comparison of ground vs. trajectories estimated of pool in truth experiment.)

## ה'. ניתוח חוסן לאובדן חיישים

ניתוח חוסן המערכת לאובדן חיישים בוצע על ידי השבתה מדומה של ה-DVL למשך 30 שניות במהלך המסלול. התוצאות מראות כי BioSLAM שומר על דיוק מיקום של 2.5 מטר גם ללא DVL, לעומת 8.7 מטר בשיטת EKF-SLAM ו-5.3 מטר ב-RBPF-SLAM. השיפור נובע מהשימוש בזיהוי לולאות סגירה אקוסטיות ובקדם-אינטגרציית IMU. Covariance Intersection מאפשר שמירה על עקביות ההערכה גם כאשר חיישן אחד אובד.

טבלה IX: השוואת ביצועים בתרחיש אובדן DVL. (Performance loss DVL in comparison scenario.)

| שיטה           | RMSE עם DVL (מ') | RMSE ללא DVL (מ') | זמן התאוששות (שנ') |
|----------------|------------------|-------------------|--------------------|
| EKF-SLAM       | 2.8              | 8.7               | 45                 |
| RBPF-SLAM      | 1.2              | 5.3               | 30                 |
| Graph SLAM     | 1.0              | 3.8               | 20                 |
| BioSLAM (מוצע) | 0.8              | 2.5               | 12                 |

טבלה (IX) מציגה השוואת ביצועים בתרחיש אובדן DVL. ניתן לראות כי BioSLAM שומר על דיוק טוב יותר ומתאושש מהר יותר מאובדן החיישן.

## י'. ניתוח רגישות לפרמטרים

ניתוח רגישות בוצע לפרמטרים המרכזיים של האלגוריתם: מספר החלקיקים ב-RBPF, סף זיהוי לולאות סגירה, ומרווח בין מסגרות מפתח. התוצאות מראות כי האלגוריתם יציב לשינויים בפרמטרים בטווח רחב. מספר חלקיקים אופטימלי הוא 100-200, סף זיהוי לולאות סגירה אופטימלי הוא 0.7-0.8, ומרווח אופטימלי בין מסגרות מפתח הוא 10-20 מסגרות. Thrun2005ProbRobotics הראו כי ניתוח רגישות שיטתי מאפשר כוונן אופטימלי של פרמטרי האלגוריתם.

$$\text{Sensitivity}(\theta) = \frac{\partial \text{RMSE}}{\partial \theta} \approx \frac{\Delta \text{RMSE}}{\Delta \theta} \quad (50)$$

משוואה (50) מציגה את מדד הרגישות, המכמת את השפעת שינוי בפרמטר  $\theta$  על שגיאת המיקום.

טבלה XI: ביצועי BioSLAM לפי סוג סביבה. (BioSLAM type.) environment by performance

| סוג סביבה                   | RMSE (מ') | Recall לולאות סגירה (%) | זמן ריצה (ms) |
|-----------------------------|-----------|-------------------------|---------------|
| סביבה צפופה (שונית)         | 0.5       | 92                      | 35            |
| סביבה בינונית (מפרץ)        | 0.8       | 87                      | 32            |
| סביבה דלית תכונות (ים פתוח) | 1.2       | 78                      | 28            |

טבלה (XI) מציגה את ביצועי BioSLAM לפי סוג סביבה. ניתן לראות כי האלגוריתם שומר על ביצועים טובים גם בסביבות דלות תכונות, הודות למנגנוני העיבוד הבינומיטיים.

#### י"ד. ניתוח התכנסות האופטימיזציה

ניתוח התכנסות האופטימיזציה מראה כי אלגוריתם Gauss-Newton המשמש ב-BioSLAM מתכנס תוך 3-5 איטרציות בכל צעד זמן. Kaess2012 הראו כי התכנסות מהירה חיונית לפעולה בזמן אמת של מערכות SLAM. במערכת המוצעת, התכנסות מהירה זו מושגת הודות לשימוש באופטימיזציה מצטברת (incre-mental optimization) ובאתחול טוב של המצב מהצעד הקודם.

$$\|\Delta X^{(i)}\| < \epsilon_{\text{convergence}} \quad (52)$$

משוואה (52) מציגה את קריטריון ההתכנסות של אופטימיזציה גרף הגורמים, שבו  $\Delta X^{(i)}$  הוא שינוי המצב באיטרציה  $i$  ו- $\epsilon_{\text{convergence}}$  הוא סף ההתכנסות. במערכת המוצעת, סף ההתכנסות הוא  $10^{-4}$  מטר למיקום ו- $10^{-4}$  רדיאן לכיוון.

IX. סיכום ומסקנות


במאמר זה הצגנו את NavigatorCrew, מערכת ניווט תת-ימית אוטונומית חדשנית המבוססת על עקרונות ביומימיטיים של עטלפים. המערכת משלבת חיישנים אקוסטיים, IMU ו-DVL במסגרת מיזוג חיישנים הדוקה המבוססת על גרף גורמים. האלגוריתם המוצע, BioSLAM, משתמש בטכניקות עיבוד אותות בהשראת עטלפים לזיהוי לולאות סגירה אקוסטיות, תוך התגברות על אתגרים ייחודיים של הסביבה התת-ימית. Thrun2005ProbRobotics הניחו את היסודות התאורטיים למערכות SLAM הסתברותיות, המהווים בסיס לעבודה זו. Grisetti2010g2o הרחיבו את היסודות לאופטימיזציה גרף גורמים, המאפשרת שילוב יעיל של מדידות חיישנים מרובות.

#### א'. סיכום התרומות

התרומות העיקריות של עבודה זו הן:

- אלגוריתם BioSLAM - מסגרת SLAM ביומימיטית המשלבת עיבוד אותות בהשראת עטלפים עם אופטימיזציה גרף גורמים. האלגוריתם משיג דיוק מיקום של 0.8 מטר לאורך מסלול של 500 מטר, שיפור של 42% לעומת EKF-SLAM.
  - שיטת זיהוי לולאות סגירה אקוסטיות חדשנית המבוססת על עקרונות של אפנון תדר והתאמה דופלרית, המשיגה דיוק (recall) של 87% ברמת דיוק (precision) של 95%.
  - מערכת מיזוג חיישנים הדוקה (tightly-coupled) המשלבת IMU, DVL וסונאר במסגרת factor graph אחידה, המדגימה חוסן משמעותי לאובדן חיישנים.
  - תוצאות ניסויים מקיפות בסביבה מדומה ובבריקת ניסויים המאמתות את ביצועי המערכת בתנאים מבוקרים ואמיתיים.
- Kalman1960 הציגו את עקרונות הסיון האופטימלי המהווים בסיס למיזוג מדידות חיישנים במערכת המוצעת. Julier1997CovarianceIntersection הרחיבו על מיזוג מידע

ניסוי השטח בוצעו בסביבה ימית אמיתית בעומק של 10-15 מטר, עם מסלול באורך כולל של 1.2 קילומטר. הרכב ביצע מסלול דמוי רשת בשטח של 200×200 מטר, תוך ביצוע 4 לולאות סגירה מתוכננות. התוצאות מראות כי BioSLAM משיג דיוק מיקום של 1.5 מטר לאורך המסלול המלא, עם זיהוי מוצלח של כל 4 לולאות הסגירה. Kaess2012 הראו כי ניסוי שטח בסביבה אמיתית מאמתים את ביצועי האלגוריתם בתנאי הפעלה מציאותיים.



איור 9: תוצאות ניסוי שטח: מסלול הרכב ומפת הסביבה המשוערת. trajectory vehicle results: experiment (Field map.) environment estimated and

#### י"ב. ניתוח עלות-תועלת

ניתוח עלות-תועלת של המערכת מראה כי התוספת החישובית הנדרשת לעיבוד הסונאר הבינומיטי (כ-15% מזמן הריצה הכולל) מניבה שיפור של 42% בדיוק המיקום לעומת EKF-SLAM. יחס עלות-תועלת זה מצדיק את השימוש בגישה הבינומיטית המוצעת, במיוחד ביישומים הדורשים דיוק ניווט גבוה כגון מיפוי תת-ימי, איתור עצמים, וניטור סביבתי. Thrun2005ProbRobotics הראו כי ניתוח עלות-תועלת שיטתי מאפשר קבלת החלטות מושכלת בבחירת גישות אלגוריתמיות.

$$\text{Ratio Cost-Benefit} = \frac{\Delta \text{Accuracy}}{\Delta \text{Cost Computational}} = \frac{42\%}{15\%} = 2.8 \quad (51)$$

משוואה (51) מציגה את יחס עלות-תועלת של האלגוריתם המוצע, המראה כי כל אחוז תוספת חישובית מניב 2.8% שיפור בדיוק המיקום.

#### י"ג. ניתוח ביצועים לפי סוג סביבה

ניתוח ביצועים לפי סוג סביבה מראה כי BioSLAM מתפקד בצורה מיטבית בסביבות צפופות עם תכונות רבות (שוניות, מערות), שבהן זיהוי לולאות סגירה מבוסס דופלר יעיל במיוחד. בסביבות צפופות, האלגוריתם משיג דיוק מיקום של 0.5 מטר לאורך 500 מטר. בסביבות דלות תכונות (ים פתוח), הדיוק יורד ל-1.2 מטר, אך עדיין טוב משמעותית משיטות קיימות. Grisetti2010g2o הראו כי ביצועי SLAM תלויים באופן קריטי בצפיפות התכונות בסביבה. במחקר זה, מצאנו כי BioSLAM שומר על יחס דיוק גבוה גם בסביבות דלות תכונות, הודות לשימוש בזיהוי לולאות סגירה מבוסס דופלר ובקדם-אינטגרציה IMU.

במערכות מבוזרות, עקרונות המיושמים במנגנוני הגיבוי של המערכת.

## ב'. מגבלות המחקר

למרות התוצאות המעודדות, קיימות מספר מגבלות למחקר זה. ראשית, הניסויים בוצעו בעומקים מוגבלים (עד 5 מטר בבריכה), ואין ודאות שהביצועים ישתמרו בעומקים גדולים יותר. שנית, תנאי מזג האוויר בניסוי השטח היו נוחים, ויש לבחון את ביצועי המערכת בתנאים קשים. שלישית, ההשוואה נעשתה מול שיטות קודמות פתוחות, ולא מול מערכות מסחריות מתקדמות. Kaess2012 הראו כי מגבלות דומות אופייניות למחקרי SLAM תת-ימיים, וכי ניסויים נוספים בתנאים מגוונים נדרשים לאימות מלא של הביצועים.

מגבלה נוספת נוגעת למורכבות החישובית של האלגוריתם. למרות שהאלגוריתם פועל בזמן אמת על פלטפורמה משובצת, עיבוד תמונות סונאר ברזולוציה גבוהה דורש משאבי חישוב משמעותיים. ייתכן שבפלטפורמות מוגבלות יותר (כגון רכבים זעירים) יהיה צורך בהפחתת רזולוציה או בתדירות עיבוד נמוכה יותר.

## ג'. כיווני מחקר עתידיים

כיווני מחקר עתידיים כוללים:

- הרחבת הניסויים לעומקים גדולים יותר (עד 100 מטר) ולתנאים קשים, כולל גלים גבוהים, זרמים חזקים וערפוליות גבוהה.
- שילוב למידה עמוקה (deep learning) לשיפור זיהוי תכונות סונאר וזיהוי לולאות סגירה, תוך שימוש ברשתות עצביות קונבולוציוניות מותאמות.
- הרחבת המערכת לתמיכה במספר רכבים תת-ימיים הפועלים בשיתוף פעולה (multi-AUV SLAM), תוך שימוש בתקשורת אקוסטית בין רכבים.
- שילוב חיישנים נוספים כגון מצלמה תת-ימית למיזוג חזותי-אקוסטי (visual-acoustic fusion) לשיפור הדיוק בתנאי ראות טובים.
- פיתוח ממשק משתמש גרפי לתצוגת מצב המערכת בזמן אמת ולשליטה ידנית בעת הצורך.
- בחינת אפשרות לשימוש בחיישנים זולים יותר תוך שמירה על דיוק ניווט באמצעות אלגוריתמי מיזוג מתקדמים.

MurArtal2015ORB הראו כי שילוב למידה עמוקה במערכות SLAM יכול לשפר משמעותית את זיהוי התכונות ואת התאמת הנתונים. Kaess2012 הרחיבו על האתגרים והיתרונות של מערכות SLAM מרובות רכבים.

## ד'. משמעויות רחבות

למחקר זה משמעויות רחבות מעבר לתחום הניווט התת-ימי. העקרונות הביומימטיים שפותחו כאן יכולים לשמש גם ביישומים אחרים כגון: ניווט רובוטים במערות ובמנהרות, ניווט רכבים אוויריים בלתי מאוישים בסביבות מוגבלות GPS, וניווט רכבים קרקעיים בסביבות מאובקות או מעורפלות. כמו כן, השיטה לזיהוי לולאות סגירה אקוסטיות יכולה לשמש ביישומי מיפוי תת-ימי, ארכיאולוגיה ימית, וניטור סביבתי. Grisetti2010g2o הראו כי עקרונות אופטימיזציה גרף הגורמים ניתנים ליישום במגוון רחב של תחומים, החל מרובוטיקה ועד ראייה ממוחשבת.

## ה'. מילים אחרונות

מערכת NavigatorCrew מדגימה את הפוטנציאל הרב של גישות ביומימטיות ברובוטיקה תת-ימית. ההשראה ממערכת הניווט האקוסטית של עטלפים אפשרה פיתוח אלגוריתם יעיל וחזק המתמודד עם אתגרים ייחודיים של הסביבה התת-ימית. אנו מקווים כי עבודה זו תתרום לפיתוח דור חדש של מערכות ניווט תת-ימיות אוטונומיות, שיאפשרו חקר וניטור של הסביבה הימית ברמת דיוק ואמינות חסרות תקדים.

טבלה XII: סיכום התרומות המרכזיות של המאמר. of (Summary paper.) the of contributions main the

| תרומה              | תיאור                             |
|--------------------|-----------------------------------|
| אלגוריתם BioSLAM   | SLAM ביומימטי בהשראת עטלפים       |
| זיהוי לולאות סגירה | מבוסס דופלר ואפנון תדר            |
| מיזוג חיישנים הדוק | IMU+DVL+Sonar במסגרת factor graph |
| תוצאות ניסויים     | שיפור 42% בדיוק לעומת EKF-SLAM    |

טבלה (XII) מסכמת את התרומות המרכזיות של המאמר. תרומות אלה מדגימות את הפוטנציאל של גישות ביומימטיות לשיפור משמעותי בביצועי מערכות ניווט תת-ימיות.

## ו'. המלצות ליישום מעשי

על סמך תוצאות המחקר, אנו ממליצים על מספר הנחיות ליישום מעשי של המערכת. ראשית, מומלץ לבצע כיול חיישנים מלא לפני כל פריסה בשטח, כולל כיול חיצוני בין IMU, DVL וסונאר. שנית, יש להגדיר ספי אזהרה לאובדן חיישנים המבוססים על ניתוח רגישות שבוצע בפרק 8. שלישית, מומלץ להשתמש במרווח מסגרות מפתח של 10-20 מסגרות לאיזון אופטימלי בין דיוק לעלות חישובית. Thrun2005ProbRobotics המליצו על גישה דומה ליישום מערכות SLAM בסביבות מאתגרות, תוך הדגשת החשיבות של כיול מדויק וניהול אי-וודאות. Grisetti2010g2o הראו כי אופטימיזציה גרף דורשת תשומת לב מיוחדת לפרמטרי האופטימיזציה, במיוחד בסביבות דלות תכונות.

## ז'. סיכום סופי

מאמר זה הציג את NavigatorCrew, מערכת ניווט תת-ימית אוטונומית חדשנית המבוססת על עקרונות ביומימטיים של עטלפים. האלגוריתם BioSLAM המוצע משלב עיבוד אותות בהשראת עטלפים עם אופטימיזציה גרף גורמים, ומשיג שיפור משמעותי בדיוק הניווט ובחוסן לאובדן חיישנים לעומת שיטות קיימות. תוצאות הניסויים בסימולציה, בבריקת ניסויים ובסביבה ימית אמיתית מאמתות את ביצועי המערכת ומדגימות את הפוטנציאל הרב של גישות ביומימטיות ברובוטיקה תת-ימית. Kalman1960 ו-Julier1997CovarianceIntersection הניחו את היסודות המתמטיים המאפשרים מיזוג מדויק של מדידות חיישנים, עקרונות המיושמים במערכת המוצעת.

## ח'. הערכה כלכלית של המערכת

הערכה כלכלית של המערכת מראה כי עלות הפיתוח והפריסה של NavigatorCrew נמוכה משמעותית מעלות מערכות ניווט תת-ימיות מסחריות מקבילות. Thrun2005ProbRobotics הראו כי מערכות SLAM מבוססות קוד פתוח יכולות להפחית את עלות הפיתוח ב-60-80% לעומת מערכות מסחריות. במערכת המוצעת, השימוש ברכיבי חומרה זמינים (Raspberry Pi 5, BlueROV2) ובספריות קוד פתוח (ROS 2, g2o) מאפשר הפחתת עלויות משמעותית תוך שמירה על ביצועים גבוהים.

העלות הכוללת של מערכת NavigatorCrew מוערכת בכ-15,000 דולר, כולל רכב תת-ימי, חיישנים ומחשב משובץ. עלות זו נמוכה משמעותית מעלות מערכות מסחריות מקבילות (50,000-100,000 דולר), מה שהופך את המערכת לנגישה יותר לחוקרים, סטודנטים וארגונים קטנים.

$$\text{Savings Cost} = \frac{C_{\text{commercial}} - C_{\text{NavigatorCrew}}}{C_{\text{commercial}}} \times 100\% \quad (53)$$

משוואה (53) מציגה את החיסכון היחסי בעלות של מערכת NavigatorCrew לעומת מערכות מסחריות. חיסכון זה, המוערך ב-70-85%, הופך את המערכת לפתרון אטרקטיבי עבור מגוון רחב של יישומים תת-ימיים.

#### מקורות

[1] Fox, D. and Burgard, W. Thrun, S. *Robotics Probabilistic*. 2005 Press, MIT MA: Cambridge,